TÜRKİYE CUMHURİYETİ
YILDIZ TEKNİK ÜNİVERSİTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

AVUSTRALYA - MELBOURNE ŞEHRİ İÇİN MAKİNE ÖĞRENMESİ ALGORİTMALARINI KULLANARAK EV FİYAT TAHMİNİ

16011701 — Atakan TEKOĞLU
16011012 — Süleyman Ali Burak ÇINAR

BİLGİSAYAR PROJESİ

Danışman
Prof. Dr. Oya KALIPSIZ

Nisan, 2020

TEŞEKKÜR

Bize ayırdıkları kıymetli zaman ve sağladıkları destek için değerli öğretim üyelerimiz Prof. Dr. Oya KALIPSIZ ve Dr. Hamza Osman İLHAN'a teşekkür ederiz.

Atakan TEKOĞLU
Süleyman Ali Burak ÇINAR

İÇİNDEKİLER

KISALTMA LİSTESİ

NaN	Not a Number
df	Data Frame
ANN	Artificial Neural Network

ŞEKİL LİSTESİ

TABLO LİSTESİ

ÖZET

Avustralya - Melbourne Şehri İçin Makine Öğrenmesi Algoritmalarını Kullanarak Ev Fiyat Tahmini

Atakan TEKOĞLU
Süleyman Ali Burak ÇINAR

Bilgisayar Mühendisliği Bölümü
Bilgisayar Projesi

Danışman: Prof. Dr. Oya KALIPSIZ

Bu raporda çeşitli makine öğrenmesi algoritmalarını kullanarak evlerin bazı özelliklerine dayanarak satış fiyatı tahmini yapmaya çalışıyoruz. Evlerin satış fiyatları oda sayısı, şehir merkezine olan uzaklık, evin tipi,garaj sayısı, toprak alanının büyüklüğü, evin bulunduğu muhite göre belirleniyor. Bunun için makine öğrenmesi algoritmaları kullanılmaktadır. Lineer regresyon, Lasso regresyon, karar ağaçları algoritması gibi algoritmalar tahmin için kullanılmaktadır. Veri temizleme işleminden sonra yaklaşık olarak 16.000 veri üzerinden tahmin işlemi yapılmaktadır. Lineer regresyon 0.600619 ,Lasso regresyon 0.600609, Decision Tree ise 0.459391 değere sahip olmaktadır.

Anahtar Kelimeler: Tahmin etmek, fiyatlandırma, makine öğrenmesi, makine öğrenmesi algoritmaları,istatistik, veri temizleme, lineer regresyon, decision tree,lasso,

ABSTRACT

HOUSING PRICE PREDICTION USING MACHINE LEARNING ALGORITHMS: THE CASE OF MELBOURNE CITY AUSTRALIA

Atakan TEKOĞLU
Süleyman Ali Burak ÇINAR

Department of Computer Engineering
Computer Project

Advisor: Prof. Dr. Oya KALIPSIZ

In this paper, we are predicting the sale price of the houses using various machine learning algorithms. Housing sales price are determined by numerous factors such as area of the property, location of the house, Rooms, garage, number of bathrooms, house type and so on. This paper uses machine learning algorithms to build the prediction model for houses. Here, machine learning algorithms such as Linear regression and Lasso Regression technique and Decision Tree are employed to build a predictive model. We have considered about housing data of 16.000 properties after data cleaning. Linear Regression, Lasso Regression and Decision Tree show the value of 0.600619, 0.600609 and 0.459391 respectively.This paper also represents significance of our approach and the methodology.

Keywords: Real Estate, Prediction Model, Linear Regression, Decision Tree, Lasso,Data Cleaning

1
GİRİŞ

Makine öğrenmesi modellerini kullanarak bir veri setine dayanarak tahminde bulunma işlemi günümüzde elektronik ve bilgisayar bilimcilerin araştırma yaptığı alanların başında gelmektedir. Bir insanın binlerce, milyonlarca bilgi bulunduran bir veri setine bakarak yüksek oranda tahminde bulunması mümkün değildir. Bunun için veriyi iyi okuyabilmeli ve yorumlayabilmek gerekir. Bu noktada yardımımıza makine öğrenmesi teknikleri yetişmektedir. Veri seti üzerinde bilgi çıkarımı yapmak ve tahminde bulunmak için makine öğrenmesi teknikleri kullanılmalıdır.

Bir veri setine dayanarak tahminde bulunma işlemi, bu veri setinin düzenli hale getirilmesi prensibine dayanır. İlk olarak veri üzerinde genel bir gözlem yapmalı ve bu gözleme dayanarak çeşitli veri temizleme işlemleri uygulanmalıdır. Veri temizleme işlemi sırasında istatistiksel metotlardan faydalanmak gereklidir.

Bu proje kapsamında Python dili ve bu dil ile kullanılan Pandas ve Numpy gibi yaygın kütüphaneler kullanılacak olup, verinin düzenlenmesi için çeşitli Python kütüphaneleri yazılacak olup, bu kütüphaneler sayesinde gerçeklenip, veri üzerinde tanımlanabilen ısı haritasına bakılarak ayrıca veri düzenlenmesi yapılacaktır.

2
ÖN İNCELEME

Projemizin sürekli ve gerçek değerli çıktılar üzerine kurulu olduğunu göz önünde bulundurarak bunun bir regresyon problemi olduğunu açık bir şekilde söylebiliriz. Buna bağlı olarak fiyat tahmini yapabilmek ve veri üzerinden modellerin çıkarım yapabilmesi için temizleme işlemi yapmak gerekmektedir. Temizleme işlemi internet üzerinde bulunan Weka gibi çeşitli yazılımlar aracığılı ile yapılabildiği gibi aynı zamanda Python kütüphaneleri kullanılarak da yapılabilmektedir.

Veri analizi yaparken anormal değerleri saptamak, veri üzerindeki kayıp değerleri bulmak, düzensiz verileri ayıklamak, hem metinsel hem de sayısal veriler içeren alanları görebilmek için istatiksel ve grafiksel yaklaşımlar ile saptama yapılacaktır.

İki değişkene dayalı olarak işlem yapılan quantitative (statistical) analysis yöntemlerinden Bivariate analysis kullanılarak veri üzerinde daha iyi bir hakimiyet sağlanacak olup, aykırı değerler temizlecektir.

Sonuç olarak bu projede oda sayısı, evin bulunduğu konum, toprak alanı gibi paramatrelere bağlı olarak ilgili ev için bir fiyat tahmini yapılması amaçlanmaktadır. Bunu yaparken çeşitli makine öğrenmesi modelleri karşılaştırıcalak olup, içlerinden en iyi sonuç veren kullanılacaktır.

Şekil-2.1 İki değişkenli olarak veri karşılaştırmasına örnektir.

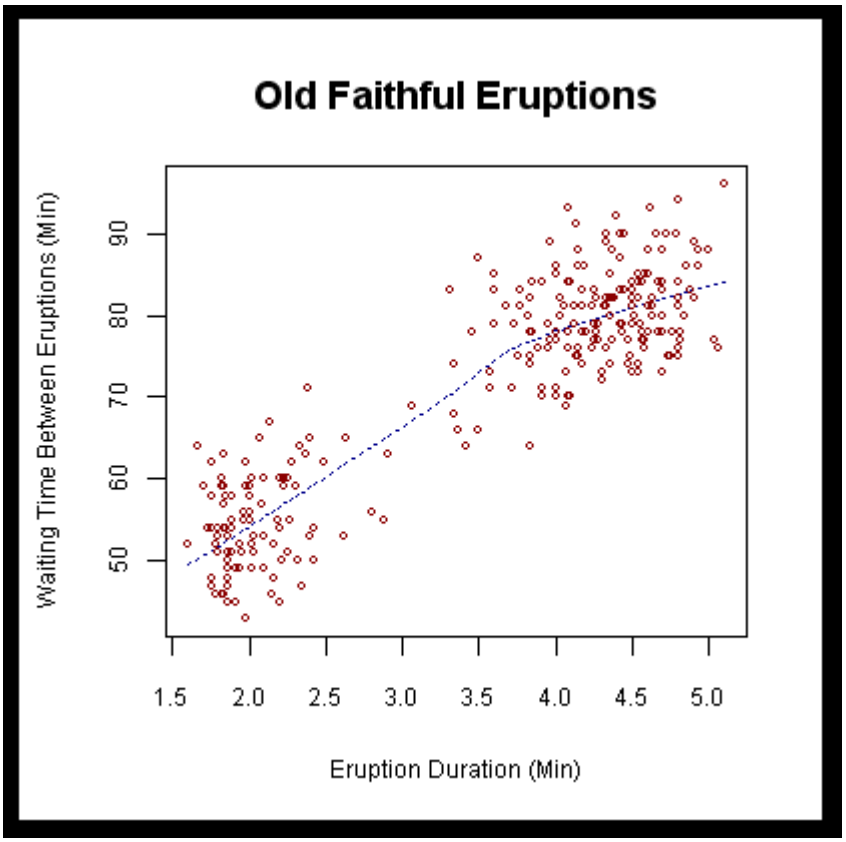

Şekil 2.1 Bivariate Analysis

3
FİZİBİLİTE

Projenin, uygun yapıda tasarlanması için gerekli araştırmalar yapılmış ve teknik yapı hazırlanmaya başlanmıştır. Kullanımı kolaylaştıracak tasarım kararları belirlenmiştir

3.1 Teknik Fizibilite

Sistemin yazılım ve donanım fizibilitesi Bölüm 3.1.1 ve Bölüm 3.1.2'de listelenmiştir

3.1.1 Yazılım Fizibilitesi

İstatiksel veri analizi ve modellerin gerçeklemek için kullanılacak elementler aşağıda listelenmiştir.

- Windows 10
- Anaconda
- Jupyter Notebook
- Android Studio

İlgili işletim sistemi ve programların tamamı ücretsizdir.

3.1.2 Donanım Fizibilitesi

Yazılım fizibilitesinde kullanılması bahsedilen uygulamayı çalıştırmak için kullanılacak bilgisayarlar minimum sistem gereksinimlerinin fazlasıyla üstündedir.Özellikler aşağıda listelenmiştir.

- 1.Bilgisayar

  - Monster ABRA A5 V12.1
  - Intel Core i5-7300 HQ CPU 2.50GHz
  - 8192MB RAM
  - NVIDIA GeForce GTX 1050 4050MB
  - 1TB 7200RPM HDD

- 2.Bilgisayar
  - Monster ABRA A5 V15.2
  - Intel Coffee Lake Core i7-9750H
  - 8GB (1x8GB) DDR4 2666MHz
  - 4GB GDDR5 Nvidia GTX1650 128-Bit
  - 1TB 7200RPM HDD + 240GB M.2 SSD Sata 3

3.1.3 İş Gücü ve Zaman Planlaması

Projenin tamamlanma süreci 101 gün olarak belirlenmiştir. Öncelikle uygun veri seti bulunup incelenecektir. Veri seti bulunduktan sonra uygun hale getirmek için özellik çıkarımı yapılacaktır. Sonrasında model oluşturmada kullanılması gereken algoritmalar bulunup araştırılacaktır. Bu algoritmaların kullanım alanlarını görebilmek için literatür taraması yapılacak, konuyla ilgili olan bilimsel çalışmalar incelenecektir. Burda amaç genel işleyişi ve çalışma mantığını anlayıp uygun algoritmanın seçilmesi için gerekli donanımı kazanmaktır. Bu süreçte yazılım kısmına başlayıp projenin teslim tarihine yetiştirilmesi sağlanacaktır. Kullanıcıya zahmetsiz bir deneyim sunmak amaciyla arayüz tasarımı yapılacaktır. Programın girdi çıktıları alınıp en iyi sonuçlara ulaşmak için karşılaştırmalar yapılacaktır.Projenin tamamlanmasında 2 adet Bilgisayar Mühendisligi 3. Sınıf Lisans öğrencisi görev alacaktır.

	Görevler	Süre	Başlangıç	Bitiş
1	Projenin Belirlenmesi	7 Gün	09.02.20	16.02.20
2	Veri Setinin Bulunması	5 Gün	16.02.20	21.02.20
3	Proje İncelemesi	2 Gün	21.02.20	23.02.20
4	Veri Seti Ön İnceleme	2 Gün	21.02.20	23.02.20
5	Özellik Çıkarımı	14 Gün	23.02.20	08.03.20
6	Fizibilite	5 Gün	08.03.20	13.03.20
7	Hedef Algoritmaların Tespiti	7 Gün	13.03.20	20.03.20
8	Toplantı	1 Gün	21.03.20	22.03.20
9	Decision Tree Algorithm	3 Gün	22.03.20	23.03.20
10	Linear Regression Algorithm	4 Gün	23.03.20	27.03.20
11	Ridge & Lasso Regression	4 Gün	27.03.20	31.03.20
12	Deep Neural Network Regression	7 Gün	31.03.20	07.04.20
13	Arayüz Tasarımı	11 Gün	07.04.20	18.04.20
14	Deneysel Sonuçlar	7 Gün	18.04.20	25.04.20
15	Yazılım Süreci	52 Gün	22.03.20	13.05.20
16	Raporlama	94 Gün	09.02.20	20.05.20

Şekil 3.1 İş Gücü ve Zaman Planlaması

3.1.4 Yasal Fizibilite

Uygulamanın üzerinde gerçekleneceği işletim sistemi Windows 10'un lisansı, Microsoft Imagine üzerinden ücretsiz olarak alınmıştır. Anaconda, Android Studio, Jupyter Notebook uygulamalarının ücretsiz lisans hakkı sağlayan Community versiyonu kullanılacaktır. Oluşturulacak platformun yasal uygunlugu araştırılarak herhangi bir hak ihlali bulunmadığı görülmüş ve sonuç olarak sistemin uygunluğuna karar verilmiştir.

3.1.5 Ekonomik Fizibilite

Sistemin yazılım, donanım ve diğer tüm giderleri Şekil3.2 ve Şekil3.3 belirtilmiştir.

Çalışan Ünvanı	Çalışan Sayısı	Aylık Maaşı
Yazılımcı	2	3.500 TL
Sistem Analisti	1	4.500 TL
Proje Yöneticisi	1	5.500 TL
Toplam		**13.500 TL**

Şekil 3.2 Çalışan Giderleri

Geliştirme Bilgisayarları	Monster Abra A5 V12.1	4.000 TL
	Monster Abra A5 V15.2	6.500 TL
İşletim Sistemi	Windows 10	Ücretsiz
IDE	Anaconda	Ücretsiz
	Android Studio	Ücretsiz
	Jupyter Notebook	Ücretsiz
Toplam		10.500 TL

Şekil 3.3 Donanım ve Yazılım Giderleri

4
SİSTEM ANALİZİ

4.1 Veri Seti Tanımlaması

Veri seti; satırlarında gözlem birimleri, sütunlarında ise değişkenler bulunan iki boyutlu bir matristir. Satır ve sütunların kesişim bölgerine hücre adı verilir. Her bir hücreye, gözlemlerin değerleri yani yapılan ölçmenin sonuçları sayı veya sembol olarak girilir.Bir hücrede herhangi bir sayı veya sembol olmaması, amaçlanan gözlemin bulunmadığını ifade eder. Bu bilgiler ışığında bizim veri setimizi tanıyabiliriz.

4.1.1 Melbourne Housing Veri Seti

Projede kullanılacak veri seti Kaggle isimli siteden alınmıştır.[1] Bu veri seti 21 özellik ve 34.857 veriden oluşmaktadır. İçerisinde 8 kategorik ve 13 sayısal alan bulunmaktadır.

Aşağıda veri setimize genel olarak bir bakış yapılmıştır.

	Suburb	Address	Rooms	Type	Price	Method	SellerG	Date	Distance	Postcode	...	Bathroom	Car	Landsize	BuildingArea	YearBuilt	C
0	Abbotsford	68 Studley St	2	h	NaN	SS	Jellis	3/09/2016	2.5	3067.0	...	1.0	1.0	126.0	NaN	NaN	
1	Abbotsford	85 Turner St	2	h	1480000.0	S	Biggin	3/12/2016	2.5	3067.0	...	1.0	1.0	202.0	NaN	NaN	
2	Abbotsford	25 Bloomburg St	2	h	1035000.0	S	Biggin	4/02/2016	2.5	3067.0	...	1.0	0.0	156.0	79.0	1900.0	
3	Abbotsford	18/659 Victoria St	3	u	NaN	VB	Rounds	4/02/2016	2.5	3067.0	...	2.0	1.0	0.0	NaN	NaN	
4	Abbotsford	5 Charles St	3	h	1465000.0	SP	Biggin	4/03/2017	2.5	3067.0	...	2.0	0.0	134.0	150.0	1900.0	
5	Abbotsford	40 Federation La	3	h	850000.0	PI	Biggin	4/03/2017	2.5	3067.0	...	2.0	1.0	94.0	NaN	NaN	
6	Abbotsford	55a Park St	4	h	1600000.0	VB	Nelson	4/06/2016	2.5	3067.0	...	1.0	2.0	120.0	142.0	2014.0	
7	Abbotsford	16 Maugie St	4	h	NaN	SN	Nelson	6/08/2016	2.5	3067.0	...	2.0	2.0	400.0	220.0	2006.0	
8	Abbotsford	53 Turner St	2	h	NaN	S	Biggin	6/08/2016	2.5	3067.0	...	1.0	2.0	201.0	NaN	1900.0	
9	Abbotsford	99 Turner St	2	h	NaN	S	Collins	6/08/2016	2.5	3067.0	...	2.0	1.0	202.0	NaN	1900.0	

10 rows × 21 columns

Şekil 4.1 Melbourne City Data Set

4.1.2 Kullanıcı Senaryosu Diyagramı

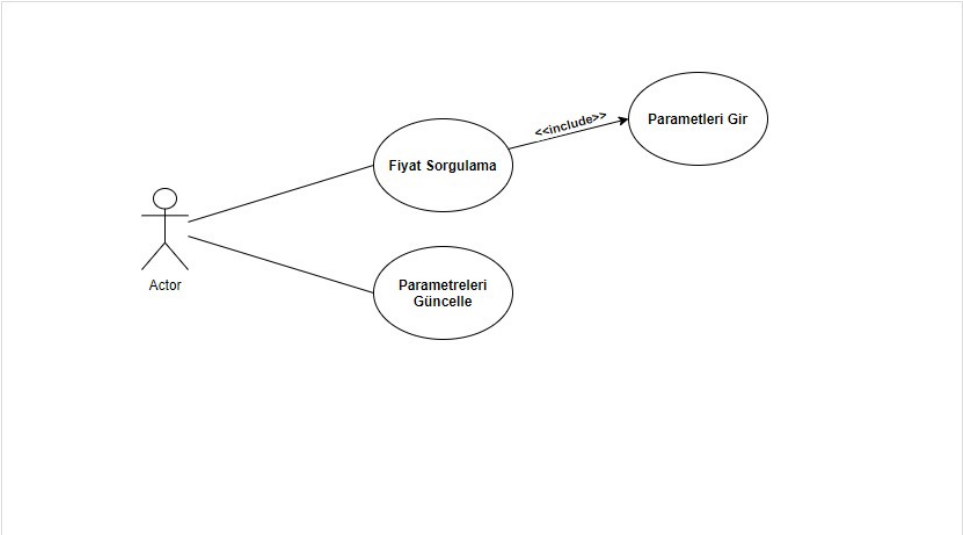

Şekil 4.2 Kullanıcı Senaryosu Diyagrımı

4.1.3 Veri Akış Diyagramı

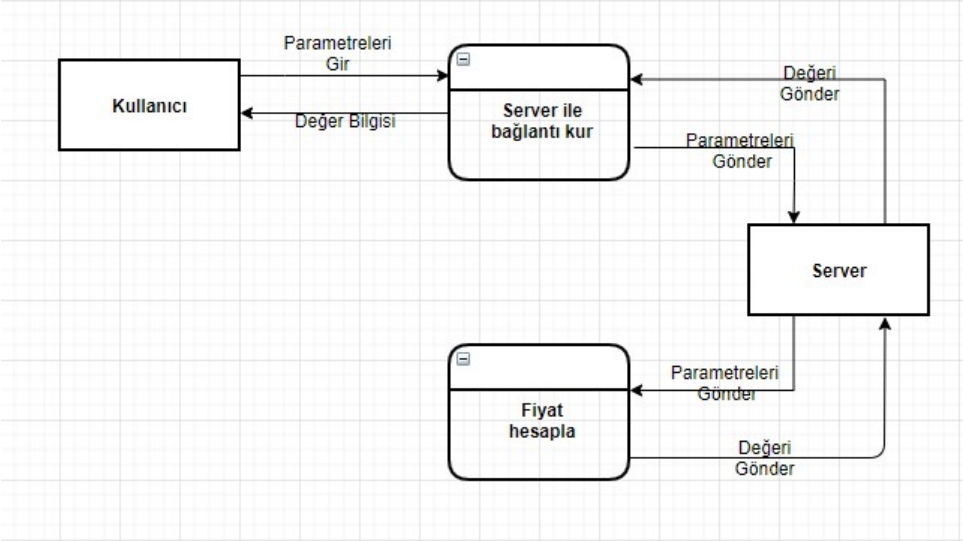

Şekil 4.3 Veri Akış Diyagramı

5
SİSTEM TASARIMI

Gerçeklenmesi planlanan projede veri seti analizi yapılıp, bu analiz üzerinden ev fiyatı tahmini yapabilmek için makine öğrenmesi modelleri kullanılacaktır. Bu modeller gelecek bölümlerde daha detaylı bir biçimde açıklanacaktır. Veri seti ham olarak 34.857 satır ve 21 sütundan oluşmaktadır. Veri seti içerisinde boş alanlar, değeri 0 olan anlamsız alanlar, kategorisi number olmasına rağmen string değer içeren değerler vardır. Böylesine yüksek miktarda bilgi barındıran ve içinde çeşitli eksiklikler barındıran veri setini matplotlib, plotly, numpy ve pandas gibi popüler python temelli kütüphaneler ile temizleme işlemi yapılacaktır. Proje kapsamında model eğitiminden sonra deneme verilerinin girilmesi ile tahmin yapma işlemi yapılması düşünülmektedir.

5.1 Veri Seti Analizi

Bu bölümde Kaggle isimli siteden alınan[1] Melbourne şehrinin verilerini barındıran veri seti incelenecektir.

5.1.1 Melbourne Housing Veri Seti

	Suburb	Address	Rooms	Type	Price	Method	SellerG	Date	Distance	Postcode	...	Bathroom	Car	Landsize	BuildingArea	YearBuilt	C
0	Abbotsford	68 Studley St	2	h	NaN	SS	Jellis	3/09/2016	2.5	3067.0	...	1.0	1.0	126.0	NaN	NaN	
1	Abbotsford	85 Turner St	2	h	1480000.0	S	Biggin	3/12/2016	2.5	3067.0	...	1.0	1.0	202.0	NaN	NaN	
2	Abbotsford	25 Bloomburg St	2	h	1035000.0	S	Biggin	4/02/2016	2.5	3067.0	...	1.0	0.0	156.0	79.0	1900.0	
3	Abbotsford	18/659 Victoria St	3	u	NaN	VB	Rounds	4/02/2016	2.5	3067.0	...	2.0	1.0	0.0	NaN	NaN	
4	Abbotsford	5 Charles St	3	h	1465000.0	SP	Biggin	4/03/2017	2.5	3067.0	...	2.0	0.0	134.0	150.0	1900.0	
5	Abbotsford	40 Federation La	3	h	850000.0	PI	Biggin	4/03/2017	2.5	3067.0	...	2.0	1.0	94.0	NaN	NaN	
6	Abbotsford	55a Park St	4	h	1600000.0	VB	Nelson	4/06/2016	2.5	3067.0	...	1.0	2.0	120.0	142.0	2014.0	
7	Abbotsford	16 Maugie St	4	h	NaN	SN	Nelson	6/08/2016	2.5	3067.0	...	2.0	2.0	400.0	220.0	2006.0	
8	Abbotsford	53 Turner St	2	h	NaN	S	Biggin	6/08/2016	2.5	3067.0	...	1.0	2.0	201.0	NaN	1900.0	
9	Abbotsford	99 Turner St	2	h	NaN	S	Collins	6/08/2016	2.5	3067.0	...	2.0	1.0	202.0	NaN	1900.0	

10 rows × 21 columns

Şekil 5.1 Veri Setine Genel Bakış

5.1.2 Veri Setinin Alanları

- Sayısal Alanlar
  - Rooms
  - Price
  - Distance
  - Postcode
  - Bedroom2
  - Bathroom
  - Car
  - Landsize
  - BuildingArea
  - YearBuilt
  - Lattitude
  - Longtitude
  - Propertycount
- Kategorik Alanlar
  - Suburb
  - Address
  - Type
  - Method
  - SellerG
  - Date
  - CouncilArea
  - Regionname

Pandas kütüphanesi ile projeye dahil edilen veri seti üzerinde çalıştırılan 'shape' fonskiyonu ile kaç adet veri ve özellik olduğu öğrenilmiştir.

```
print("Veri Sayısı:{0}  Özellik Sayısı:{1}".format(df.shape[0],df.shape[1]))
```

```
Veri Sayısı:34857  Özellik Sayısı:21
```

Şekil 5.2 Veri ve Özellik Sayısı İçin Çalışan Kod

- **Veri Seti Hakkında**
  - Veri sayısı: 34.857
  - Özellik Sayısı: 21

5.2 Veri Seti Tasarımı

5.2.1 Veri Temizleme

Bu noktadan sonra veri seti üzerine yorumlanabilirlik sağlanması gerekmektedir.Şekil 5.1 bizlere veri seti hakkında genel olarak bilgi verirken, Şekil 5.2 ise veri sayısı ve özellik bilgisini aktarıyor.Öte yandan alanlara göre veri tipi tanımlaması yapmaktadır. Bu bilgiyi ise Şekil 5.3 de görebiliriz.

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 34857 entries, 0 to 34856
Data columns (total 21 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   Suburb         34857 non-null  object
 1   Address        34857 non-null  object
 2   Rooms          34857 non-null  int64
 3   Type           34857 non-null  object
 4   Price          27247 non-null  float64
 5   Method         34857 non-null  object
 6   SellerG        34857 non-null  object
 7   Date           34857 non-null  object
 8   Distance       34856 non-null  float64
 9   Postcode       34856 non-null  float64
 10  Bedroom2       26640 non-null  float64
 11  Bathroom       26631 non-null  float64
 12  Car            26129 non-null  float64
 13  Landsize       23047 non-null  float64
 14  BuildingArea   13742 non-null  float64
 15  YearBuilt      15551 non-null  float64
 16  CouncilArea    34854 non-null  object
 17  Lattitude      26881 non-null  float64
 18  Longtitude     26881 non-null  float64
 19  Regionname     34854 non-null  object
 20  Propertycount  34854 non-null  float64
dtypes: float64(12), int64(1), object(8)
memory usage: 5.6+ MB
```

Şekil 5.3 Veri Tipleri

Veri setinde yüksek miktarda işe yaramaz alan bulunmaktadır. Bu alanlar veri seti üzerinde olumsuz etki yapmaktadır. Bu alanları Şekil 5.4 de büyükten küçüğe doğru sıralanmış vaziyette görmekteyiz.

Bizim için en fazla önem arz eden alan satış fiyatıdır. Satış fiyatı için histogram görünümü elde edelim ve yorumlayalım.

```
df.isnull().sum().sort_values(ascending=False)
```

```
BuildingArea     21115
YearBuilt        19306
Landsize         11810
Car               8728
Bathroom          8226
Bedroom2          8217
Longtitude        7976
Lattitude         7976
Price             7610
Regionname           3
Propertycount        3
CouncilArea          3
Postcode             1
Distance             1
Date                 0
SellerG              0
Method               0
Type                 0
Rooms                0
Address              0
Suburb               0
dtype: int64
```

Şekil 5.4 Veri Seti Üzerindeki NaN alanlar

Şekil 5.5 de görüleceği üzere histogram skew değeri 2.5889693410528607 ile right skew olarak görünüyor.Right skewed dağılıma sahip bir kümede mean değerinin median değerinden büyük olduğu söylenebilir.

```
plt.hist(df['Price'])
plt.show()
```

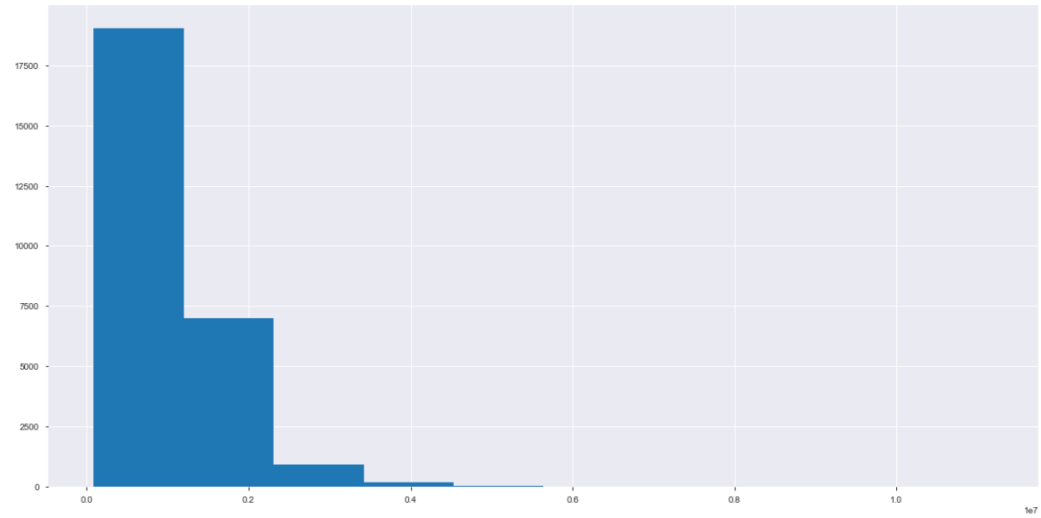


```
print("Skew of price:",df['Price'].skew())
```

```
Skew of price: 2.5889693410528607
```

Şekil 5.5 Ev Fiyatının Histogram Görüntüsü

Daha iyi bir anlayış için Correlation Matrix ile görselize hale getirelim. Şekil 5.6 de görülen Correlation Matrix de iki özellik arasında doğrusal bir ilişki olup olmadığı, varsa bu ilişkinin şiddetini görüyoruz. Şekilde ayrıca korelasyon kat sayılarıda görülmektedir. Korelasyon kat sayısı için aşağıdaki listede yorum yapılmıştır.[2]

- **Korelasyon katsayı(r) nın yorumu**
  - r<0.2 ise çok zayıf ilişki yada korelasyon yok
  - 0.2-0.4 arasında ise zayıf korelasyon
  - 0.4-0.6 arasında ise orta şiddette korelasyon
  - 0.6-0.8 arasında ise yüksek korelasyon
  - 0.8> ise çok yüksek korelasyon olduğu yorumu yapılır.

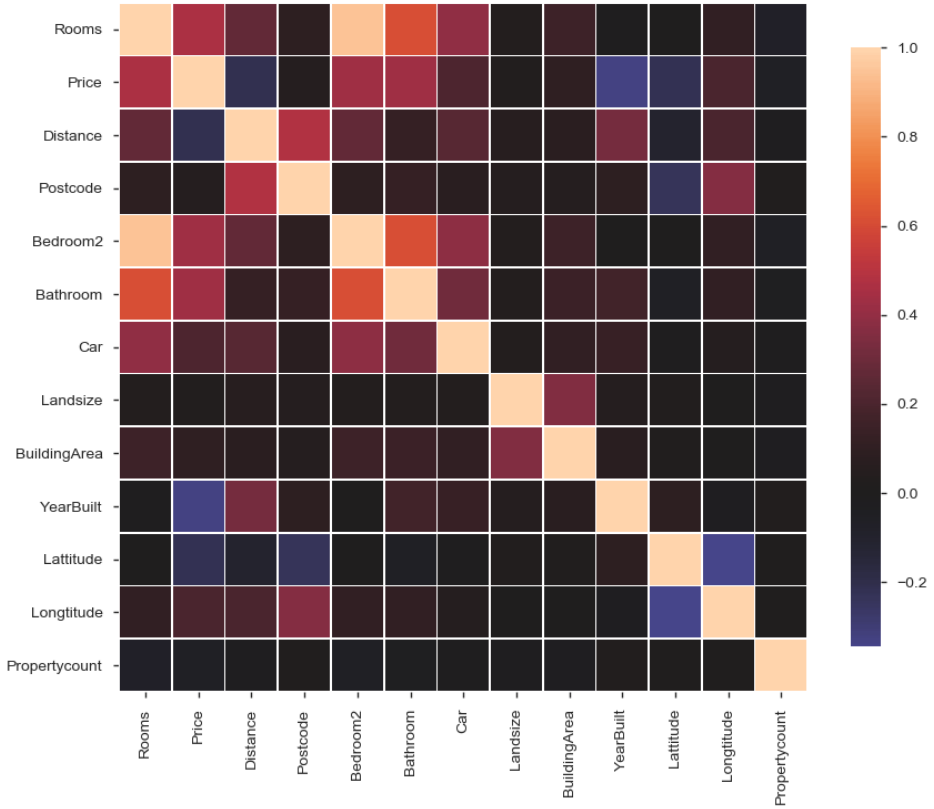

Şekil 5.6 Correlation Matrix

Şekil 5.4 de belirtildiği üzere veri setinin 6 alanındaki verilen çoğu kayıp verilerden oluşmaktadır.

Şekil 5.6 den yola çıkarak veri üzerindeki 'Address','SellerG','Suburb','YearBuilt','Lattitude', 'Longtitude','YearBuilt','Bedroom2','Date','Method','Propertycount','Regionname','Postcode'gibi

alanların bazılarının özellik olarak birbirine benzediği görülüyor. Bundan dolayı bu alanların silinmesi gerekmektedir.

Bu alanlar silindikten sonra veri set Şekil 5.7 de belirtildiği gibi görülmektedir.

	Rooms	Type	Price	Distance	Bathroom	Car	Landsize	BuildingArea	CouncilArea
0	2	h	NaN	2.5	1.0	1.0	126.0	NaN	Yarra City Council
1	2	h	1480000.0	2.5	1.0	1.0	202.0	NaN	Yarra City Council
2	2	h	1035000.0	2.5	1.0	0.0	156.0	79.0	Yarra City Council
3	3	u	NaN	2.5	2.0	1.0	0.0	NaN	Yarra City Council
4	3	h	1465000.0	2.5	2.0	0.0	134.0	150.0	Yarra City Council

Şekil 5.7 Alanlar Silindikten Sonra Veri Setine Bakış

BuildingArea ve Landsize alanlarında bulunan NaN değerlerini kaldırmak için Şekil 5.8 de belirtilen fonksiyon yazılmıştır.[3] Veri sayımız bu işlemden sonra 19.256 olmuştur.

```
df4=df3.dropna(subset=['BuildingArea','Landsize'], thresh = 1)
df4.shape
```

```
(19256, 9)
```

Şekil 5.8 BuildingArea ve Landsize Alanlarının Temizlenmesi

Not a Number alanları temizlendikten sonra hiçbir alanın boş kalmaması için ilgili konumlar bulunup 0 değeri ile doldurulur. Şekil 5.9 da öncesi ve sonrası görülmektedir.

Feature	Number of Null Values
BuildingArea	8600
Landsize	1274
Car	320
Bathroom	9
CouncilArea	0
Distance	0
Price	0
Type	0
Rooms	0

Feature	Number of Null Values
CouncilArea	0
BuildingArea	0
Landsize	0
Car	0
Bathroom	0
Distance	0
Price	0
Type	0
Rooms	0

Şekil 5.9 Boş Alanların Doldurulduktan Sonraki Görüntüsü

BuildingArea ve Landsize alanlarının benzerliği nedeniyle iki alanın değerleri toplanım Total isimli yeni bir değişken içerisinde değerlendirilmiştir. Bu sayede modelin performansının artırılması amaçlanmıştır. Şekil 5.10 de yapılan işlem belirtilmiştir.

```
df6 = df5.copy()
df6['Total'] = df6['Landsize'] + df6['BuildingArea']
df6.head()
```

	Rooms	Type	Price	Distance	Bathroom	Car	Landsize	BuildingArea	CouncilArea	Total
1	2	h	1480000.0	2.5	1.0	1.0	202.0	0.0	Yarra City Council	202.0
2	2	h	1035000.0	2.5	1.0	0.0	156.0	79.0	Yarra City Council	235.0
4	3	h	1465000.0	2.5	2.0	0.0	134.0	150.0	Yarra City Council	284.0
5	3	h	850000.0	2.5	2.0	1.0	94.0	0.0	Yarra City Council	94.0
6	4	h	1600000.0	2.5	1.0	2.0	120.0	142.0	Yarra City Council	262.0

Şekil 5.10 Total Alanın Belirtilmesi

Landsize ve Buildingarea bir düşünüldüğü için bu iki alana gerek kalmamıştır. Bu iki alanı attıktan sonra aşağıda veri setinin alanları görülmektedir.

```
df8 = df7.drop(['Landsize','BuildingArea'],axis = 'columns')
df8.head()
```

	Id	Rooms	Type	Price	Distance	Bathroom	Car	CouncilArea	Total
1	2	2	h	1480000.0	1	1.0	1.0	Yarra City Council	202.0
2	3	2	h	1035000.0	1	1.0	0.0	Yarra City Council	235.0
4	5	3	h	1465000.0	1	2.0	0.0	Yarra City Council	284.0
5	6	3	h	850000.0	1	2.0	1.0	Yarra City Council	94.0
6	7	4	h	1600000.0	1	1.0	2.0	Yarra City Council	262.0

Şekil 5.11 Landsize ve Buildingarea Silindikten Sonra Veri Seti

Distance alanını incelediğimizde içerisindeki değerlerin birbirine çok yakın olduğu görülmektedir. Bu yakınlık distance özelliğinin parametrik olarak girilmesine olanak tanımıyor. Şekil 5.12 de birbirinden farklı olan tüm distance değerlerini görebiliyoruz.

```
df.Distance.unique()
```

```
array([ 2.5, 13.5,  3.3,  6.4, 13.8, 11.1,  6.3,  5.9, 11. , 12.2, 10.5,
        6.6,  9.7,  9.2, 13. , 13.9, 13.1, 10.8, 11.2, 10.7,  5.2, 11.8,
       11.7,  7.8,  9. ,  3.2, 11.4,  8.9,  8.1,  9.3, 13.6,  3.4,  1.6,
       10.3,  8.5,  7.7,  8. ,  9.4,  5.8,  3.5,  4.4, 12.1, 13.7, 14.5,
        4.6,  7.9, 15. , 12.8,  4.2,  5.6,  7.5,  6.2,  7.4,  8.7,  2.8,
        4.1,  6.9, 14.6,  8.4,  2.3,  5.5, 11.5, 14.7,  2.6,  9.9,  3.8,
        4.5,  8.8,  2.1,  1.2,  6.1, 12.6, 13.3,  6.5, 14.9,  1.9,  5.1,
        7. ,  9.1,  9.5,  1.8,  1.5,  9.8, 12.4, 10.6,  8.2, 10.9, 10.4,
       14. , 12.5,  5.3, 12.7,  3.7,  3. ,  5.7, 15.5,  4.3, 10.2, 16.5,
       23.2, 17.3, 35.2, 13.4, 25. , 16.1,  4. , 14.8, 10.1, 17.9, 17.5,
       16.7,  3.6, 43.4,  6.7, 20.6, 34.7, 23. , 24.7, 21.8, 22.2, 14.3,
       25.9,  1.3, 27. , 18. ,  7.2, 36.9, 19.6, 28.8, 24.8, 15.4, 38. ,
       45.9, 12.9,  7.3, 20.4, 32.3, 45.2, 21.3, 16. , 18.4, 12.3,  5.4,
       25.2, 16.3, 33.8, 31.7, 29.8, 20. , 17.2, 16.2, 21.5, 14.2, 18.8,
       34.1, 22.7, 12. ,  2.4, 19.9, 23.8, 23.5, 15.2, 35.4, 20.5,  2.7,
       20.8,  5. , 30.4, 15.3,  3.1, 17.6, 25.5, 27.2,  8.6, 31.2,  2. ,
        1.4,  0. , 26.5, 47.3,  0.7, 21.1, 23.6,  6.8, 34.9, 18.7, 26. ,
       41. , 47.4, 39.8, 27.1, 17.4, 37.5, 33.3, 31.6, 34.6, 44.2, 27.7,
       23.3, 29.3, 26.1, 29.9, 28.5, 43.3, 30.6, 39. , 31.4, 20.1, 35.5,
       48.1, 16.6, 22.9, 33. ,  nan, 29.5, 32.6])
```

Şekil 5.12 Distance Unique Alanlar

Bir fonksiyon yazarak bu alanları 4 kategoride birleştirirsek parametre olarak girebiliriz.

- Distance 0: Değer 0
- Distance 0 ile 5 arasında: Değer 1
- Distance 5 ile 25 arasında: Değer 2
- Diğer Durumlar: 3

Şekil5.13 de kullanılan fonksiyon ve elde edilen çıktı görülmektedir.

```
def set_distance(x):
    if x == 0:
        return 0
    elif 0 < x < 5:
        return 1
    elif 5<= x <= 25 :
        return 2
    else:
        return 3
df7 = df6.copy()
df7['Distance'] = df7['Distance'].apply(set_distance)
df7.Distance.unique()
```

```
array([1, 2, 3, 0], dtype=int64)
```

Şekil 5.13 Fonksiyon Sonrası Distance Alanları

Oluşan son durumdan sonra veri setimizde bulunan alanların fiyat ile olan dağılımlarını ilişkisel olarak görebilmek için plot çizdirelim. Takip eden kısımlarda Rooms, Type, Distance,Total, Bathroom, Car ve CouncilArea alanları için Price alanı ile olan ilişki grafiksel olarak gösterilmiştir.

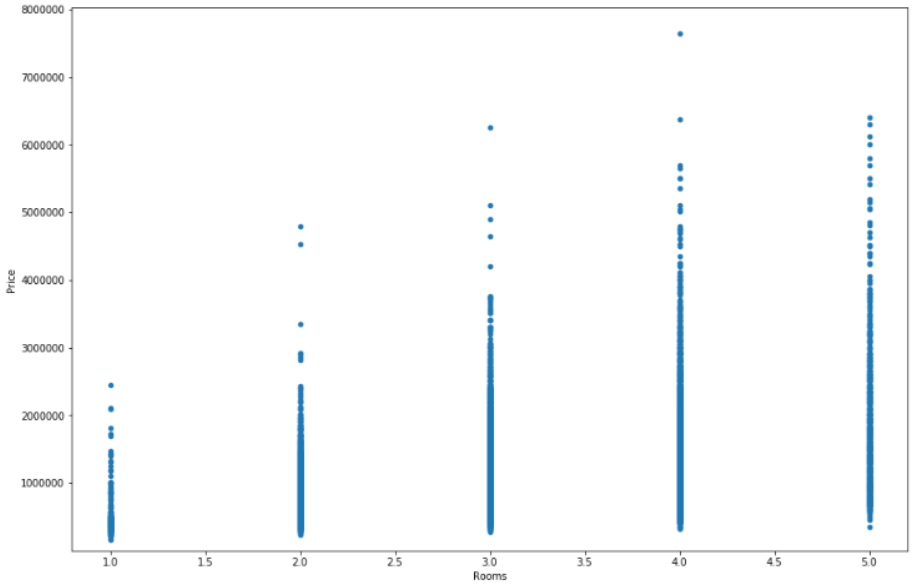

Şekil 5.14 Price - Rooms İlişkisi

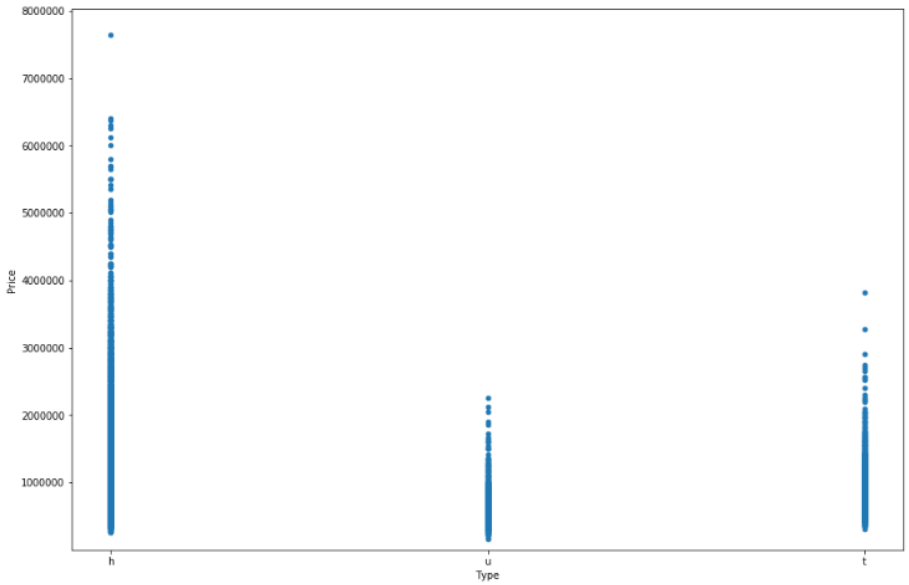

Şekil 5.15 Price - Type İlişkisi

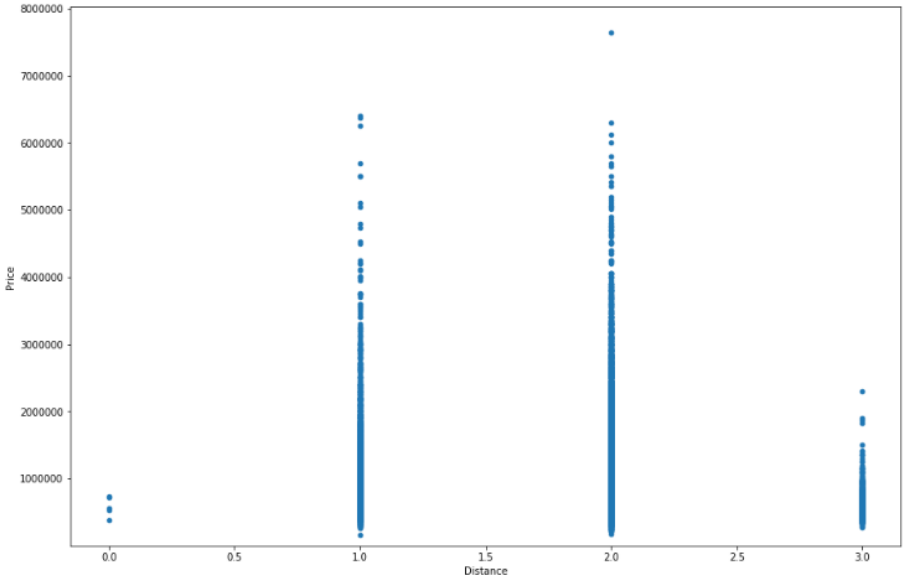

Şekil 5.16 Price - Distance İlişkisi

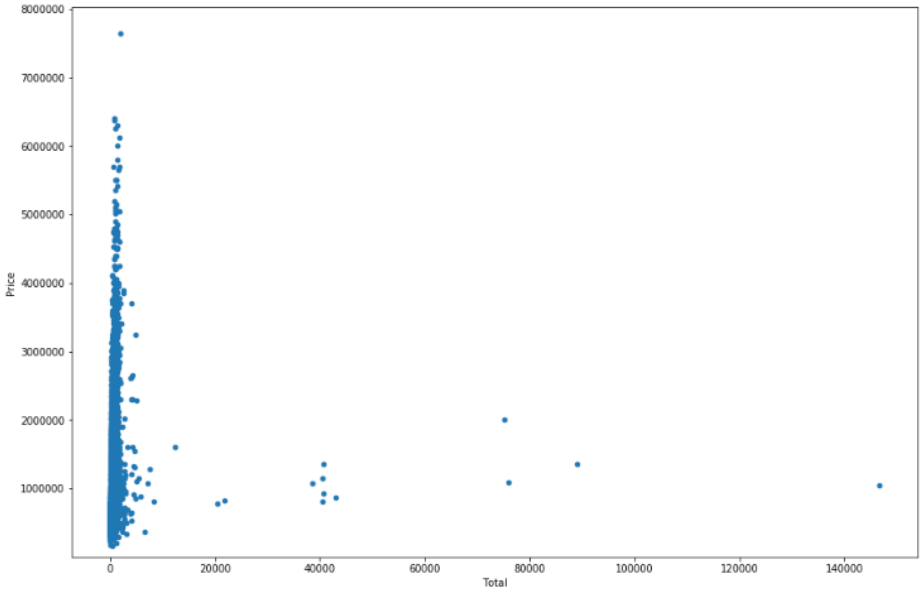

Şekil 5.17 Price - Total İlişkisi

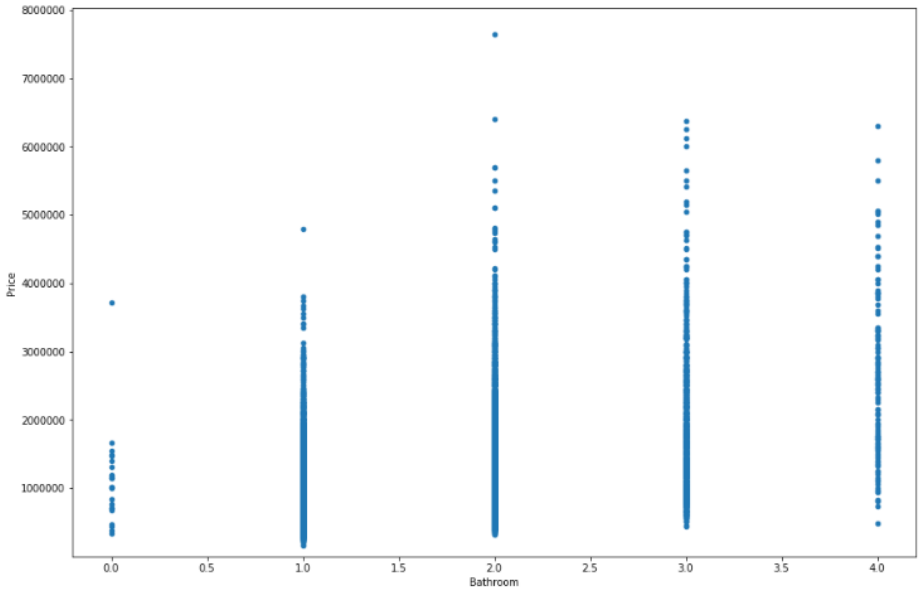

Şekil 5.18 Price - Bathroom İlişkisi

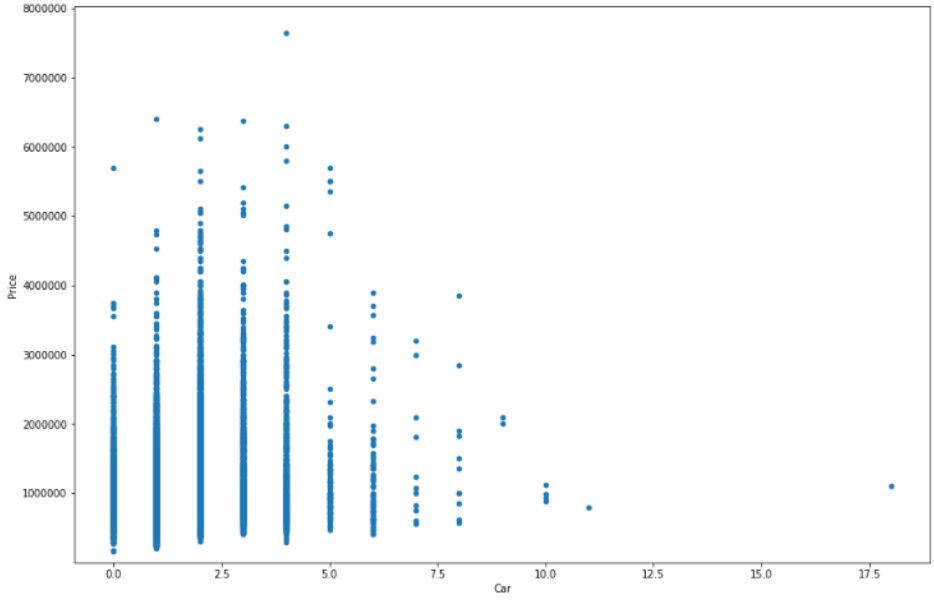

Şekil 5.19 Price - Car İlişkisi

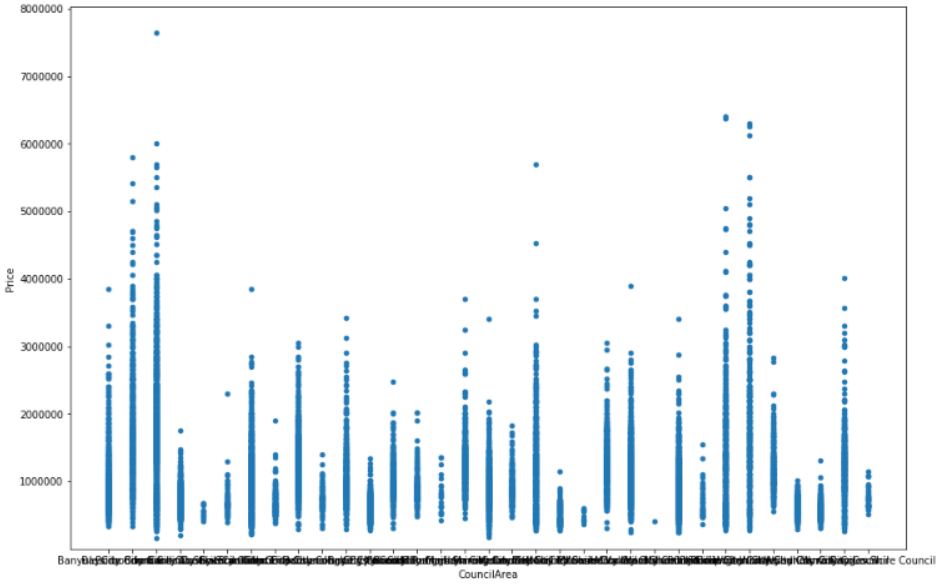

Şekil 5.20 Price - CouncilArea İlişkisi

Veri setimizin son halini Şekil 5.21

Out[335]:

	Id	Rooms	Type	Price	Distance	Bathroom	Car	CouncilArea	Total
0	3719	5	h	1901000.0	2	2.0	2.0	Banyule City Council	1188.0
1	3721	4	h	1650000.0	2	3.0	2.0	Banyule City Council	1051.0
2	3726	3	h	1816000.0	2	1.0	2.0	Banyule City Council	1026.0
3	3727	2	u	525000.0	2	1.0	1.0	Banyule City Council	149.0
4	3728	4	h	2050000.0	2	3.0	2.0	Banyule City Council	1013.0

Şekil 5.21 Veri Setinin Son Hali

5.2.2 Veri Setinin Model İçin Hazırlanması

Veri setinin son halinde elimizde kategorik veriler bulunmakta. Bu kategorik verileri getdummies [4] adlı pandas fonksiyonu ile random göstergeçlere çevireceğiz.İlk olarak CouncilArea alanını Şekil 5.22 görüldüğü üzere dummies isimli değişkende tutacağız.

```
dummies = pd.get_dummies(f1.CouncilArea)
dummies.head()
```

	Banyule City Council	Bayside City Council	Boroondara City Council	Brimbank City Council	Cardinia Shire Council	Casey City Council	Darebin City Council	Frankston City Council	Glen Eira City Council	Greater Dandenong City Council	...	Moorabool Shire Council	Moreland City Council	Nillumbik Shire Council	Port Phillip City Council	Stonn City C
0	1	0	0	0	0	0	0	0	0	0	...	0	0	0	0	
1	1	0	0	0	0	0	0	0	0	0	...	0	0	0	0	
2	1	0	0	0	0	0	0	0	0	0	...	0	0	0	0	
3	1	0	0	0	0	0	0	0	0	0	...	0	0	0	0	
4	1	0	0	0	0	0	0	0	0	0	...	0	0	0	0	

5 rows × 33 columns

Şekil 5.22 CouncilArea Alanının Sayısal Alana Çevrilmesi

Daha sonra Şekil 5.23 de görüldüğü üzere Type alanını dummies2 isimli değişkende tutuyor olacağız.

```
dummies2 = pd.get_dummies(f1.Type)
dummies2.head()
```

	h	t	u
0	1	0	0
1	1	0	0
2	1	0	0
3	0	0	1
4	1	0	0

Şekil 5.23 Type Alanının Sayısal Alana Çevrilmesi

İki farklı değişken içindeki bu alanlar ve asıl veri setimizi tek bir değişkende toplamak için ise yine bir Pandas fonksiyonu olan concat isimli fonksiyonu kullanacağız.

```
f2 = pd.concat([f1,dummies,dummies2],axis='columns')
f2.head()
```

pe	Price	Distance	Bathroom	Car	CouncilArea	Total	Banyule City Council	...	Port Phillip City Council	Stonnington City Council	Whitehorse City Council	Whittlesea City Council	Wyndham City Council	Yarra City Council	Yarra Ranges Shire Council	h	t	u
h	1901000.0	2	2.0	2.0	Banyule City Council	1188.0	1	...	0	0	0	0	0	0	0	1	0	0
h	1650000.0	2	3.0	2.0	Banyule City Council	1051.0	1	...	0	0	0	0	0	0	0	1	0	0
h	1816000.0	2	1.0	2.0	Banyule City Council	1026.0	1	...	0	0	0	0	0	0	0	1	0	0
u	525000.0	2	1.0	1.0	Banyule City Council	149.0	1	...	0	0	0	0	0	0	0	0	0	1
h	2050000.0	2	3.0	2.0	Banyule City Council	1013.0	1	...	0	0	0	0	0	0	0	1	0	0

Şekil 5.24 Tüm Alanların Tek Bir Değişken İçinde Birleştirilmesi

Artık CouncilArea ve Type alanlarını veri setimizden silebiliriz. Ayrıca alaksız özellik olan Id değerinide siliyoruz. temp isimli değişkende ise sonradan kullanılmak üzere ayrıca bir kopya alınıyor.

```
temp = f2.drop(['Type','CouncilArea'],axis = 'columns')
f3 = f2.drop(['Id','Type','CouncilArea'],axis = 'columns')
f3.head()
```

	Rooms	Price	Distance	Bathroom	Car	Total	Banyule City Council	Bayside City Council	Boroondara City Council	Brimbank City Council	...	Port Phillip City Council	Stonnington City Council	Whitehorse City Council	Whittlesea City Council	Wyndhar Cit Counc
0	5	1901000.0	2	2.0	2.0	1188.0	1	0	0	0	...	0	0	0	0	
1	4	1650000.0	2	3.0	2.0	1051.0	1	0	0	0	...	0	0	0	0	
2	3	1816000.0	2	1.0	2.0	1026.0	1	0	0	0	...	0	0	0	0	
3	2	525000.0	2	1.0	1.0	149.0	1	0	0	0	...	0	0	0	0	
4	4	2050000.0	2	3.0	2.0	1013.0	1	0	0	0	...	0	0	0	0	

5 rows × 42 columns

Şekil 5.25 Id - CouncilArea - Type Alanlarının Silinmesi

5.3 Makine Öğrenmesi Algoritmaları

Yaygın olarak kulllanılan açık kaynak kodlu makine öğrenmesi kütüphanesi olan Scikit-Learn(sklearn) [5] ile işlemlerimize devam edeceğiz.

İlk olarak modele giydirilecek olan veri setinin içinde Price değeri olmamalı.[6] Price değerini göz ardı edip X isimli değişken içinde geri kalan tüm verileri depoluyoruz. Ardından Price değerini y isimli değişkende tutuyoruz. Şekil 5.26

```
X = f3.drop(['Price'],axis='columns')
X.head(3)
```

	Rooms	Distance	Bathroom	Car	Total	Banyule City Council	Bayside City Council	Boro
0	5	2	2.0	2.0	1188.0	1	0	
1	4	2	3.0	2.0	1051.0	1	0	
2	3	2	1.0	2.0	1026.0	1	0	

3 rows × 41 columns

```
y = f3.Price
y.head(3)
```

```
0    1901000.0
1    1650000.0
2    1816000.0
Name: Price, dtype: float64
```

Şekil 5.26 X ve y Değişkenleri

Şimdi tahmin oluşturmak için sklearn tarafından bize sunulan traintestsplit methodu ile test verilerimizi oluşturalım.

Burda traintestsplit işleminden kısaca bahsedicek olursak; dizilerimizi veya matrislerimizi rastgele subsetlere ve test datalarına dönüştürüyoruz.

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X,y,test_size=0.2,random_state=10)
```

Şekil 5.27 traintestsplit Metodu

5.3.1 Linear Regression

LinearRegression nesnesi ile modelimizi oluşturalım ve train datamız ile de modelimizi besleyelim. Ardından score değerimizin, hata payımızın RMSE [7] olarak öğrenelim.

```
from sklearn import linear_model
from sklearn import ensemble
lr = linear_model.LinearRegression()
model = lr.fit(X_train, y_train)
```

```
print ("R^2 is: \n", model.score(X_test, y_test))
predictions = model.predict(X_test)
```

```
R^2 is:
 0.6117386364935725
```

Şekil 5.28 LinearRegression nesnesi ve RMSE Değeri

RMSE: Bir makine öğrenmesi modelinin, tahminleyicinin tahmin ettiği değerler ile gerçek değerleri arasındaki uzaklığın bulunmasında sıklıkla kullanılan, hatanın büyüklğünü ölçen kuadratik bir metriktir. RMSE tahmin hatalarının (kalıntıların) standart sapmasıdır. Yani, kalıntılar, regresyon hattının veri noktalarından ne kadar uzakta olduğunun bir ölçüsüdür.

Şimdi bir grafik üzerinde nasıl bir sonuç alındığını görüntüleyelim.

```
actual_values = y_test
plt.scatter(predictions, actual_values, alpha=.75,
            color='g') #alpha helps to show overlapping data
plt.xlabel('Predicted Price')
plt.ylabel('Actual Price')
plt.title('LinearRegression Model')
```

Şekil 5.29 Tahmin Verilerinin Görselize Edilmesi İçin Fonksiyon

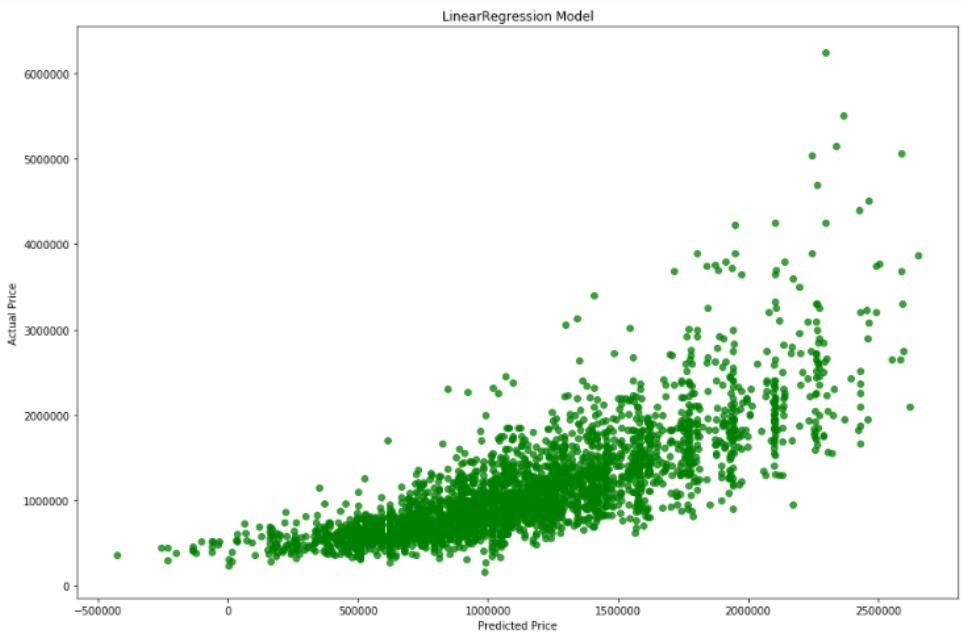

Şekil 5.30 Tahmin Verilerinin Görselize Edilmesi

5.3.2 GridSearchCV

GridSearchCV üzeriden parametrelere göre en uygun model için bir seçme işlemi yapalım. Linear Regression, Lasso Regression ve DecisionTreeRegressor arasından en iyi seçim için bir fonksiyon oluşturalım.

```
from sklearn.model_selection import GridSearchCV
from sklearn.linear_model import Lasso
from sklearn.tree import DecisionTreeRegressor
def find_best_model_using_gridsearchcv(X,y):
    algos = {
        'linear_regression' : {
            'model': LinearRegression(),
            'params': {
                'normalize': [True, False]
            }
        },
        'lasso': {
            'model': Lasso(),
            'params': {
                'alpha': [1,2],
                'selection': ['random', 'cyclic']
            }
        },
        'decision_tree': {
            'model': DecisionTreeRegressor(),
            'params': {
                'criterion' : ['mse','friedman_mse'],
                'splitter': ['best','random']
            }}}
    scores = []
    cv = ShuffleSplit(n_splits=5, test_size=0.2, random_state=0)
    for algo_name, config in algos.items():
        gs =  GridSearchCV(config['model'], config['params'], cv=cv, return_train_score=False)
        gs.fit(X,y)
        scores.append({
            'model': algo_name,
            'best_score': gs.best_score_,
            'best_params': gs.best_params_
        })

    return pd.DataFrame(scores,columns=['model','best_score','best_params'])

find_best_model_using_gridsearchcv(X,y)
```

Şekil 5.31 GridSearch İçin Fonksiyon

Tablo 5.1 de en farklı modellerin score ları görülmektedir.

model	best_score	best_param
linear_regression	0.600619	{'normalize': False}
lasson	0.600605	{'alpha': 2, 'selection': 'cyclic'}
decision_tree	0.459135	{'criterion': 'friedman_mse', 'splitter': 'ran...

Tablo 5.1 GridSearchCV Best Decision

5.3.3 Ridge Regressor

Şimdi veri setimizi Ridge Regressor modele giydirelim. Ve neticesinde RMSE değerini görelim. 5 farklı öğrenme değeri üzerinden işlem yürüteceğiz.

- alpha 0.01
- alpha 0.1
- alpha 1
- alpha 0.10
- alpha 0.100

Şimdi linearmodel'i sklearn kütüphanesinden import edip Ridge Regressor model için fonksiyon oluşturulım.

```
from sklearn import linear_model
%matplotlib inline
for i in range (-2, 3):
    alpha = 10**i
    rm = linear_model.Ridge(alpha=alpha)
    ridge_model = rm.fit(X_train, y_train)
    preds_ridge = ridge_model.predict(X_test)
    actual_values = y_test
    plt.scatter(preds_ridge, actual_values, alpha=.75, color='r')
    plt.xlabel('Predicted Price')
    plt.ylabel('Actual Price')
    plt.title('Ridge Regularization with alpha = {}'.format(alpha))
    overlay = 'R^2 is: {}\nRMSE is: {}'.format(
                    ridge_model.score(X_test, y_test),
                    mean_squared_error(y_test, preds_ridge))
    plt.annotate(s=overlay,xy=(12.1,10.6),size='x-large')
    plt.show()
```

Şekil 5.32 Ridge Regressor İçin Fonksiyon

Bu fonksiyon neticesinde alpha değerlerine göre aşağıdaki çıktıları görselize bir biçimde görüyoruz.

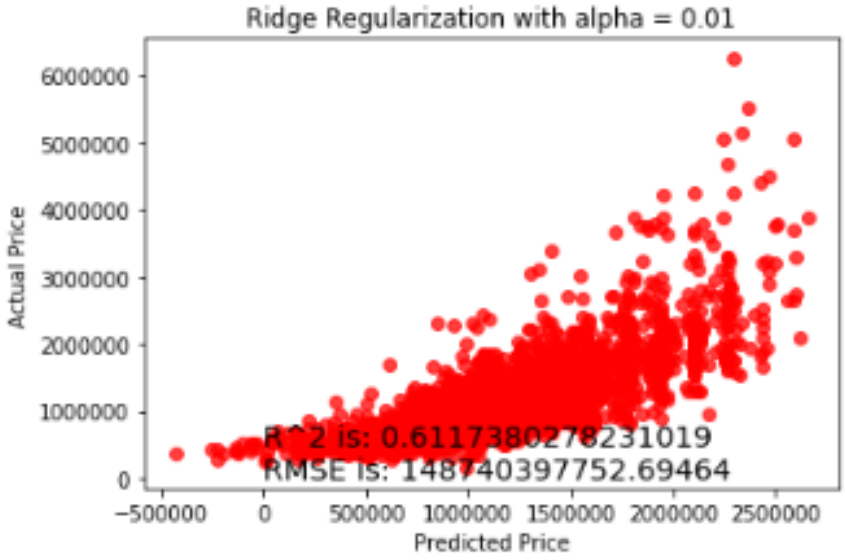

Şekil 5.33 alpha 0.01

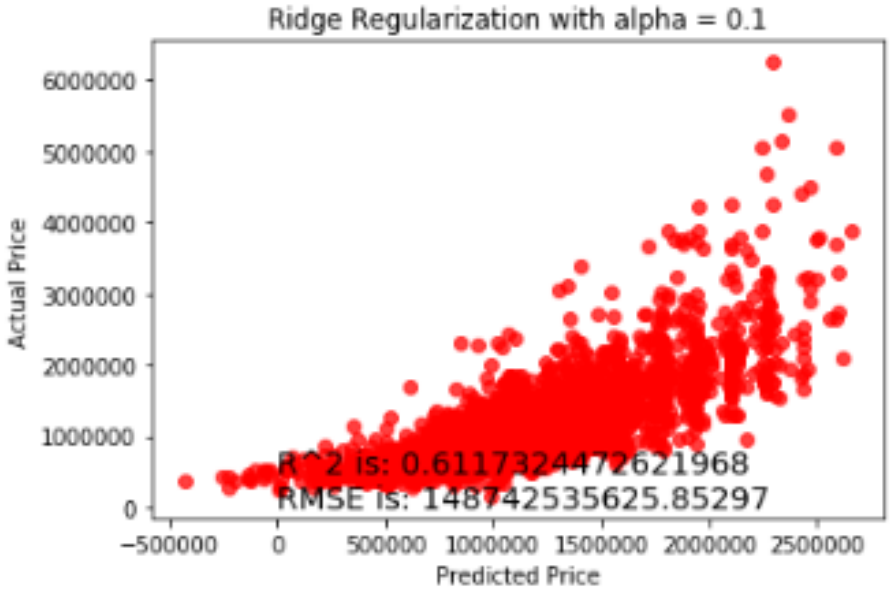

Şekil 5.34 alpha 0.1

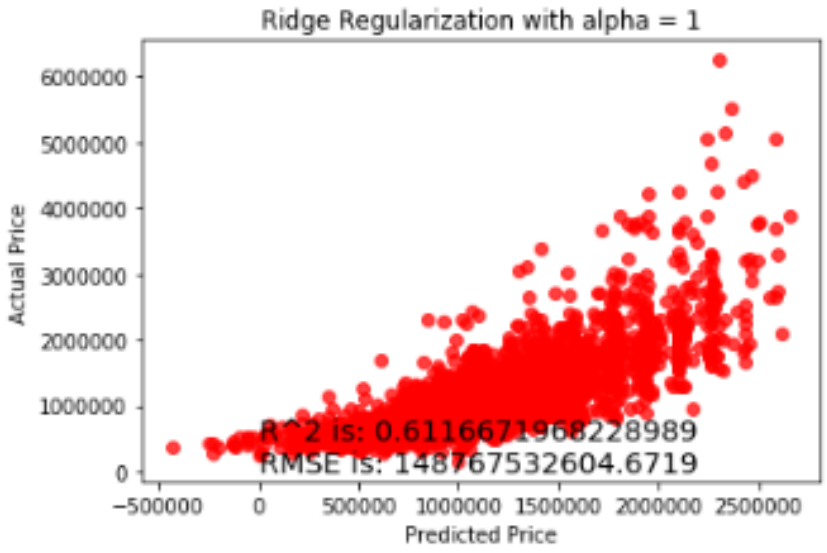

Şekil 5.35 alpha 1

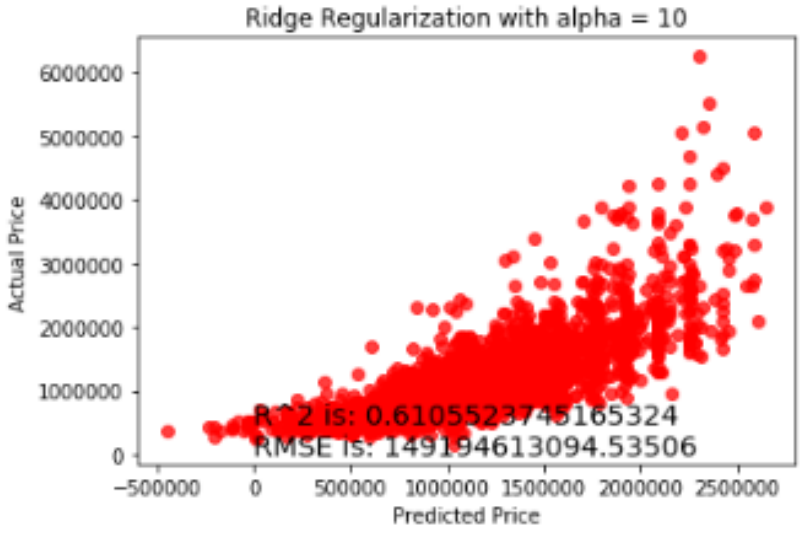

Şekil 5.36 alpha 10

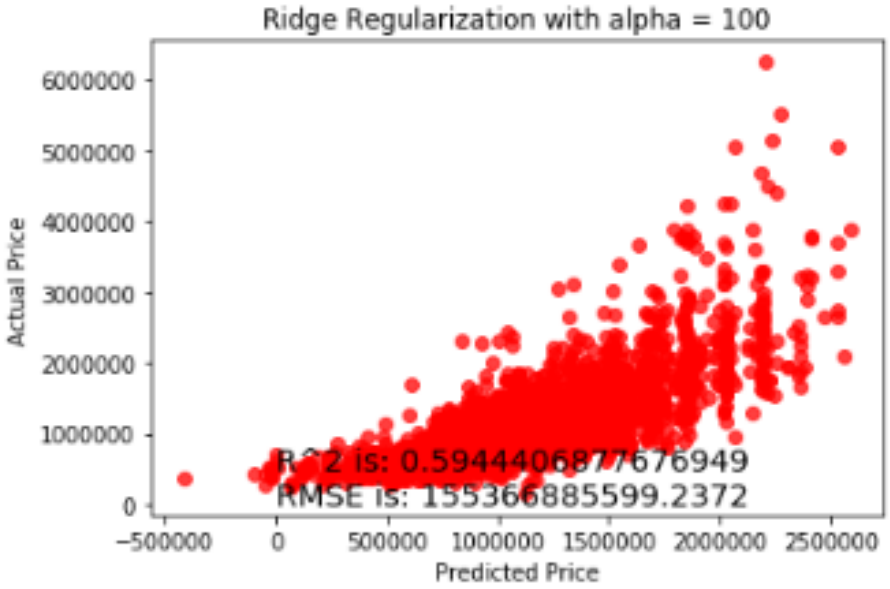

Şekil 5.37 alpha 100

5.4 Yapay Sinir Ağları

5.4.1 ANN 2 Layers

Makine öğrenmesi teknilerinden biri olan derin öğrenmeyi projemize entegre etmeye çalışalım. Kastedilen şey yapay sinir ağlarından başka bir şey değil. Yapacağımız şey Keras adlı açık kaynak kodlu kütüphaneyi dahil etmek.

Şu an zaten elimizde düzenlenmiş bir veri seti var. Bu veri setini tekrar ayarlamak gerekecek. Veri setini ilk olarak iki parçaya bölüyoruz. Şekil 5.38 de train data ve Şekil 5.39 de test data görünmektedir. Bu data elimizde olan düzenlenmiş veri setinden alınarak 2 parçaya bölünmüştür.

Id	Rooms	Price	Distance	Bathroom	Car	Total	Banyule C	Bayside Ci	Boroonda	Brimbank	Cardinia S	Casey City	Dareb
3719	5	1901000	2	2	2	1188	1	0	0	0	0	0	
3721	4	1650000	2	3	2	1051	1	0	0	0	0	0	
3726	3	1816000	2	1	2	1026	1	0	0	0	0	0	
3727	2	525000	2	1	1	149	1	0	0	0	0	0	
3728	4	2050000	2	3	2	1013	1	0	0	0	0	0	
3729	5	1930000	2	2	1	1175	1	0	0	0	0	0	
3730	2	2850000	2	1	1	1777	1	0	0	0	0	0	
3731	4	2600000	2	2	3	1193	1	0	0	0	0	0	
3733	2	600000	2	1	1	207	1	0	0	0	0	0	
3735	3	1601000	2	1	1	1008	1	0	0	0	0	0	
3736	3	1100000	2	2	1	855	1	0	0	0	0	0	
3738	4	2550000	2	2	2	1962	1	0	0	0	0	0	
3741	4	2012000	2	3	2	842	1	0	0	0	0	0	
3744	4	2309000	2	3	2	1468	1	0	0	0	0	0	
5365	2	815000	2	1	2	709	1	0	0	0	0	0	
5368	3	720000	2	1	0	505	1	0	0	0	0	0	
5369	4	1370000	2	2	4	481	1	0	0	0	0	0	
5370	2	757000	2	2	2	275	1	0	0	0	0	0	
5371	3	740600	2	2	2	337	1	0	0	0	0	0	
5372	3	580000	2	1	1	577	1	0	0	0	0	0	
5373	2	565000	2	2	1	308	1	0	0	0	0	0	
5381	4	758500	2	2	3	510	1	0	0	0	0	0	

Şekil 5.38 Train Data

Id	Rooms	Distance	Bathroom	Car	Total	Banyule C	Bayside Ci	Boroonda	Brimbank	Cardinia S	Casey
19636	3	2	1	2	520	0	0	0	0	0	
19638	4	2	1	2	870	0	0	0	0	0	
19640	2	2	1	2	519	0	0	0	0	0	
19641	3	2	2	1	536	0	0	0	0	0	
19642	3	2	1	1	540	0	0	0	0	0	
19643	2	2	1	1	363	0	0	0	0	0	
19708	3	2	2	2	333	0	0	0	0	0	
19709	3	2	2	2	339	0	0	0	0	0	
19747	4	2	3	2	720	0	0	0	0	0	
19878	4	2	1	1	560	0	0	0	0	0	
19879	4	2	1	1	452	0	0	0	0	0	
19882	3	2	1	4	601	0	0	0	0	0	
19884	4	2	1	5	565	0	0	0	0	0	
19957	3	2	2	1	409	0	0	0	0	0	
20156	2	2	1	0	270	0	0	0	0	0	
20157	4	2	3	4	422	0	0	0	0	0	
20193	4	2	1	6	953	0	0	0	0	0	
20194	3	2	2	2	150	0	0	0	0	0	
20195	3	2	2	3	623	0	0	0	0	0	
20197	3	2	1	1	298	0	0	0	0	0	
20198	3	2	1	2	741	0	0	0	0	0	
20199	2	2	1	2	558	0	0	0	0	0	

Şekil 5.39 Test Data

Şekil 5.40 de görüldüğü gibi daha sonra bu iki veri setini birleştirip, id alanını sonradan çıktı alırken sıra bozulmaması için bir değişken içerisinde depolayacağız.

```
train=pd.read_csv("train.csv")
test=pd.read_csv("test.csv")
```

```
data = pd.concat([train, test],axis=0, sort='False', ignore_index = True)
```

```
data = data[data.columns.difference(['Id'])]
```

```
ids = test["Id"]
```

Şekil 5.40 Veri Birleşimi ve Id Değerinin Saklanması

Daha sonra veriyi train ve test data olmak üzere ikiye ayırıyoruz.

```
train = data.iloc[:4000,:] #Upto 4000 rows from first
test = data.iloc[4000:,:] # From 4000 row to last
X_train = train[train.columns.difference(['Price'])].values
y_train = train[['Price']].values
X_test = test[test.columns.difference(['Price'])].values
```

Şekil 5.41 Verinin İkiye Ayrılması

Değerlerin aynı aralığa veya aynı ölçeğe yerleştirilmesi ve böylece hiçbir değişkenin diğerine baskın olmaması için feature scaling yapıyoruz. [8] [9]

```
from sklearn.preprocessing import StandardScaler, PowerTransformer
pt_X = PowerTransformer(method='yeo-johnson', standardize=False)
sc_y = StandardScaler()
sc_X = StandardScaler()
y_train = sc_y.fit_transform(y_train)
X_train = sc_X.fit_transform(X_train)
X_test = sc_X.transform(X_test)
```

Şekil 5.42 Feature Scaling

Sırada modelimizi başlatmak var.[10] Daha sonra katmanlarımızı ekliyoruz.(5.43)

```
#Initialising the ANN
model = model()
#Adding the input layer and first hidden layer
model.add(Dense(units =480, kernel_initializer='random_uniform', activation= 'tanh',
                input_dim=X_train.shape[1]))
#Add the second hidden layer
model.add(Dense(units =480, kernel_initializer='random_uniform', activation= 'tanh'))
#Add the second hidden layer
model.add(Dense(units =10, kernel_initializer='random_uniform', activation= 'relu'))
#The output layer
model.add(Dense(units =1, kernel_initializer='random_uniform', activation= 'elu'))
```

Şekil 5.43 Model Initialize ve Katman Ekleme ANN 2 Layers

Daha sonra ağırlık güncelleme değeri **epoch** 150 yapılarak işleme başlıyoruz. [11]

```
#Compiling the ANN
opt = keras.optimizers.Adam(lr=0.0015, beta_1=0.9, beta_2=0.999,decay=0.0, amsgrad=False)
model.compile(optimizer=opt, loss='mean_squared_logarithmic_error', metrics=['mse'])
#Fitting the ANN to the training set
model_filepath = 'min_vl_model.h5'
checkpoint = ModelCheckpoint(model_filepath, monitor = 'val_loss', verbose=1, save_best_only = True, mode='min' )
model.fit(X_train,y_train, validation_split=0.07, batch_size=32, nb_epoch=150, callbacks=[checkpoint])
model.load_weights(model_filepath)
```

Şekil 5.44 ANN 2 Layers Fitting

Tahmin yapma işlemi Şekil 5.45 de uygulanıyor. Daha sonra Şekil 5.46 da tahmin edilen değerler görülüyor.

```
y_pred = model.predict(X_test)
```

```
y_pred = sc_y.inverse_transform(y_pred)
```

Şekil 5.45 ANN 2 Katmanlı Tahmin İşlemi

```
y_pred.head()
```

	Id	SalePrice
0	19636.0	2908567.50
1	19638.0	3139891.25
2	19640.0	3411094.50
3	19641.0	2307300.25
4	19642.0	3184729.25

Şekil 5.46 ANN 2 Katmnalı Tahmin Değerleri

5.4.2 ANN 3 Layers

3 Katmanlı olarak aynı işlemleri tekrar edelim.

```
from keras.initializers import he_normal
from keras.layers.normalization import BatchNormalization

#Initialising the ANN
model = Sequential()
#Adding the input layer and first hidden layer
model.add(Dense(units =300, kernel_initializer=he_normal(seed=None), activation= 'tanh',
                input_dim=X_train.shape[1]))

model.add(Dropout(0.2))

#Add the first hidden layer
model.add(Dense(units =100, kernel_initializer=he_normal(seed=None), activation= 'tanh'))
model.add(Dropout(0.2))

#Add the second hidden layer
model.add(Dense(units =80, kernel_initializer=he_normal(seed=None), activation= 'relu'))
model.add(BatchNormalization())
model.add(Dropout(0.2))

#Add the third hidden layer
model.add(Dense(units =50, kernel_initializer=he_normal(seed=None), activation= 'relu'))
model.add(BatchNormalization())

#The output layer
model.add(Dense(units =1, kernel_initializer=he_normal(seed=None), activation= 'elu'))
```

Şekil 5.47 Model Initialize ve Katman Ekleme ANN 3 Layers

```
#Compiling the ANN
opt = keras.optimizers.Adam(lr=0.0015, beta_1=0.9, beta_2=0.999,decay=0.0, amsgrad=False)
model.compile(optimizer=opt, loss='mean_squared_logarithmic_error', metrics=['mse'])
#Fitting the ANN to the training set
model_filepath = 'min_vl_model3.h5'
checkpoint = ModelCheckpoint(model_filepath, monitor = 'val_loss', verbose=1, save_best_only = True, mode='min' )
model.fit(X_train,y_train, validation_split=0.07, batch_size=32, nb_epoch=200, callbacks=[checkpoint])
model.load_weights(model_filepath)
```

```
Train on 3719 samples, validate on 281 samples
Epoch 1/200
3719/3719 [==============================] - 2s 471us/step - loss: 0.1018 - mse: 0.6270 - val_loss: 4.9888e-04 - val
532

Epoch 00001: val_loss improved from inf to 0.00050, saving model to min_vl_model3.h5
Epoch 2/200
3719/3719 [==============================] - 0s 91us/step - loss: 0.0710 - mse: 0.4060 - val_loss: 4.9888e-04 - val_
09

Epoch 00002: val_loss did not improve from 0.00050
Epoch 3/200
3719/3719 [==============================] - 0s 100us/step - loss: 0.0588 - mse: 0.3595 - val_loss: 4.9888e-04 - val
635

Epoch 00003: val_loss did not improve from 0.00050
Epoch 4/200
3719/3719 [==============================] - 0s 131us/step - loss: 0.0534 - mse: 0.3314 - val_loss: 4.9888e-04 - val
655
```

Şekil 5.48 ANN 3 Layers Fitting and Compile

```
y_pred = model.predict(X_test)
```

```
y_pred = sc_y.inverse_transform(y_pred)
```

Şekil 5.49 ANN 3 Katmanlı Tahmin İşlemi

```
y_pred.head()
```

	Id	SalePrice
0	19636.0	8.815904e+05
1	19638.0	7.723262e+05
2	19640.0	8.312766e+05
3	19641.0	1.143470e+06
4	19642.0	7.975538e+05

Şekil 5.50 ANN 3 Katmnalı Tahmin Değerleri

5.4.3 ANN 5 Layers

5 Katmanlı olarak aynı işlemleri tekrar edelim.

```
from keras.initializers import he_normal
from keras.layers.normalization import BatchNormalization

#Initialising the ANN
model = Sequential()
#Adding the input layer and first hidden layer
model.add(Dense(units =150, kernel_initializer=he_normal(seed=None), activation= 'tanh',
                input_dim=X_train.shape[1]))



#Add the first hidden layer
model.add(Dense(units =100, kernel_initializer=he_normal(seed=None), activation= 'tanh'))
model.add(Dropout(0.2))

#Add the second hidden layer
model.add(Dense(units =80, kernel_initializer=he_normal(seed=None), activation= 'tanh'))
model.add(BatchNormalization())
model.add(Dropout(0.2))

#Add the third hidden layer
model.add(Dense(units =50, kernel_initializer=he_normal(seed=None), activation= 'tanh'))


#Add the fourth hidden layer
model.add(Dense(units =30, kernel_initializer=he_normal(seed=None), activation= 'relu'))
model.add(BatchNormalization())

#Add the fifth hidden layer
model.add(Dense(units =10, kernel_initializer=he_normal(seed=None), activation= 'relu'))
model.add(BatchNormalization())

#The output layer
model.add(Dense(units =1, kernel_initializer=he_normal(seed=None), activation= 'elu'))
```

Şekil 5.51 Model Initialize ve Katman Ekleme ANN 5 Layers

```
opt = keras.optimizers.Adam(lr=0.0015, beta_1=0.9, beta_2=0.999,decay=0.0, amsgrad=False)
model.compile(optimizer=opt, loss='mean_squared_logarithmic_error', metrics=['mse'])
#Fitting the ANN to the training set
model_filepath = 'min_vl_model4.h5'
checkpoint = ModelCheckpoint(model_filepath, monitor = 'val_loss', verbose=1, save_best_only = True, mode='min' )
history=model.fit(X_train,y_train, validation_split=0.07, batch_size=32, nb_epoch=400, callbacks=[checkpoint])
model.load_weights(model_filepath)
```

```
Train on 3719 samples, validate on 281 samples
Epoch 1/400
3719/3719 [==============================] - 1s 225us/step - loss: 0.0738 - mse: 0.4496 - val_loss: 0.0018 - val_mse: 0.2010

Epoch 00001: val_loss improved from inf to 0.00177, saving model to min_vl_model4.h5
Epoch 2/400
3719/3719 [==============================] - 0s 80us/step - loss: 0.0607 - mse: 0.3749 - val_loss: 0.0068 - val_mse: 0.4105

Epoch 00002: val_loss did not improve from 0.00177
Epoch 3/400
3719/3719 [==============================] - 0s 78us/step - loss: 0.0521 - mse: 0.3478 - val_loss: 0.0085 - val_mse: 0.4233

Epoch 00003: val_loss did not improve from 0.00177
Epoch 4/400
3719/3719 [==============================] - 0s 79us/step - loss: 0.0503 - mse: 0.3398 - val_loss: 0.0058 - val_mse: 0.3303

Epoch 00004: val_loss did not improve from 0.00177
Epoch 5/400
3719/3719 [==============================] - 0s 80us/step - loss: 0.0486 - mse: 0.3365 - val_loss: 0.0095 - val_mse: 0.3969
```

Şekil 5.52 ANN 5 Layers Fitting and Compile

```
y_pred = model.predict(X_test)
```

```
y_pred = sc_y.inverse_transform(y_pred)
```

Şekil 5.53 ANN 3 Katmanlı Tahmin İşlemi

```
y_pred.head()
```

	Id	SalePrice
0	19636.0	1213643.00
1	19638.0	1044929.50
2	19640.0	1304359.00
3	19641.0	1411648.00
4	19642.0	1099935.25

Şekil 5.54 ANN 5 Katmnalı Tahmin Değerleri

6
UYGULAMA

Android projemiz 3 ana klasör bulunduruyor.

- **manifests:** Kullanılan izinler ve versiyonları içeren dosya.
- **java:** Bütün java kodlarını içeren dosya.
- **res:** Layout ve media dosyalarını tutar.

6.1 Arayüz

Projenin arayüzü kolay kullanım esasına dayalı olarak tasarlanmıştır. Kullanıcı evin konum, şehre olan uzaklık ve durum özelliklerine açılır liste şeklinde ulaşırken oda sayısı, banyo sayısı, garaj sayısı ve evin alanı gibi özellikleri ilgili alanlara girerek belirtecektir.

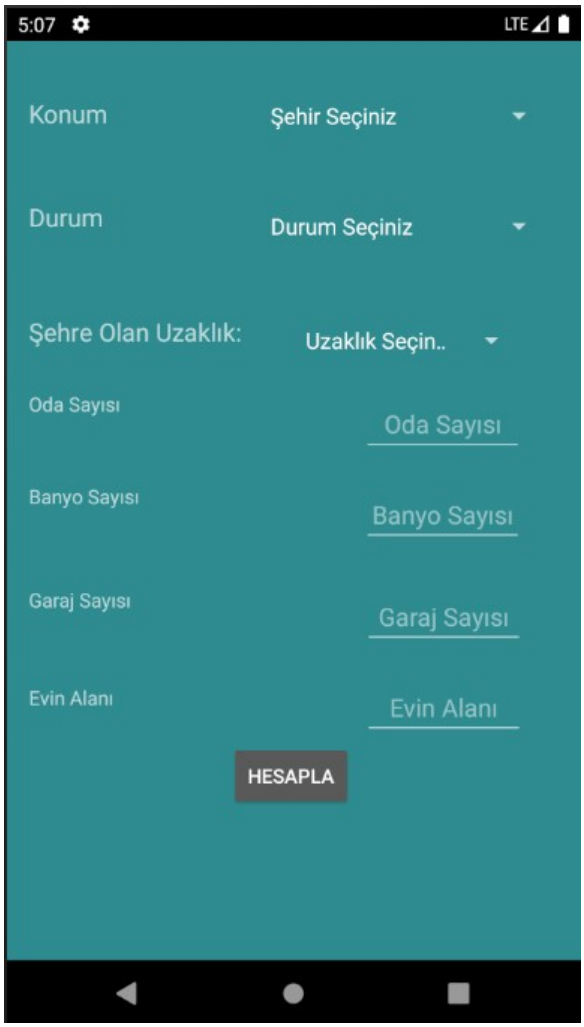

Şekil 6.1 Uygulama Görüntüsü

Kullanıcı arayüz üzerinde fiyatını merak ettiği evin özelliklerini girip hesapla dedikten sonra girdiği özelliklerdeki evin fiyat tahminini ekranında görecektir.

6.2 Parametre Girişi İçin İşlevsellik

Değerleri tutabilmek adına mapping yapmak gerekir. Bunun için JSON formatını kullanmaktayız.POST API isteklerinde bulunan veriyi geçirebilmek adına adına JSON mapping yaparız.

Aşağıda Şekil 6.2 de uygulama için kullanılan değişkenler belirtilmiştir. Spinner sınıfı kullanılarak bir set üzerinden kolayca seçim yapma işlemi sağlanmıştır.[12]

```
public class MainActivity extends AppCompatActivity {

    private TextView value;
    private Spinner location,state,uzaklık;
    private EditText odaSayısı,banyoSayısı,garajSayısı,mxm;

    JSONObject jObj = new JSONObject();

    @Override
    protected void onCreate(Bundle savedInstanceState) {
        super.onCreate(savedInstanceState);
        setContentView(R.layout.activity_main);
        value = (TextView) findViewById(R.id.textView4);

        location = (Spinner) findViewById(R.id.Location);
        state = (Spinner) findViewById(R.id.State);
        uzaklık = (Spinner) findViewById(R.id.Uzaklık);

        odaSayısı = (EditText) findViewById(R.id.OdaSayısı);
        banyoSayısı = (EditText) findViewById(R.id.BanyoSayısı);
        garajSayısı = (EditText) findViewById(R.id.GarajSayısı);
        mxm = (EditText) findViewById(R.id.mxm);

        createSpinner();

    }
```

Şekil 6.2 Uygulama Değişkenleri

onCreate() fonksiyonu ile layout elementleri başlatılır. Daha sonra ise API istekleri için bu kutulara girilen değerleri gönderebilmek için JSON objelerine çevirmemiz gerekir. Bunun için **makeJSON** isimli fonksiyon kullanılır.[13]

```
public void makeJSON(String location, String type,
String distance, String rooms, String bathroom, String car, String total){
    try{
        jObj.put("Locations" , location);
        jObj.put("Rooms",rooms);
        jObj.put("Distance",distance);
        jObj.put("Bathroom",bathroom);
        jObj.put("Car",car);
        jObj.put("Total",total);
        jObj.put("Type",type);
    }
    catch(Exception e){
        System.out.println("Error: " + e );
    }
    Log.i("",jObj.toString());
}
```

Şekil 6.3 makeJSON Fonksiyonu

6.3 Model'e Hizmet Eden RESTful API İçin İşlevsellik Ekleme

Buton tetiklendiği zaman API harekete geçmelidir. Bunu yapmak için takip eden fonksiyonlar kullanılır.

- **ByPostMethod:** Uygulamamızda servera veri göndermek ve gelen veriyi okumak için kullandığımız methodumuz.Parametre olarak serverın adresini almaktadır. Alınan adrese JSON formatına çevrilmiş bilgiler gönderirilir ve responseInputStream tipindeki değişkeninde tutulur. Methodumuz serverdan gelen cevabı tutan InputStream değişkenini döndürür.

```
InputStream ByPostMethod (String ServerURL){
    InputStream DataInputStream = null;
    try{
        URL url = new URL(ServerURL);

        HttpURLConnection connection  = (HttpURLConnection) url.openConnection();
        connection.setDoOutput(true);
        connection.setDoInput(true);
        connection.setInstanceFollowRedirects(false);
        connection.setRequestMethod("POST");
        connection.setRequestProperty("Content-Type","application/json");
        connection.setRequestProperty("charset", "utf-8");
        connection.setUseCaches(false);
        DataOutputStream dos = new DataOutputStream(connection.getOutputStream());
        dos.writeBytes(jObj.toString());
        dos.flush();
        dos.close();

        int response = connection.getResponseCode();
        if(response == HttpURLConnection.HTTP_OK){
            DataInputStream = connection.getInputStream();
        }
    }
    catch(Exception e){
        Log.e("Error caught", "Error in get data", e);
    }
    return DataInputStream;
}
```

Şekil 6.4 ByPostMethod Fonksiyonu

- **ConvertStreamToString:** methodumuz parametre olarak ByPostMethod unun dönderdiği InputStream tipinde değişken alır. Bu methodun amacı serverdan InputStream olarak aldığımız bilgilerin stringe çevrilmesini sağlamaktır.

```
String ConvertStreamToString(InputStream stream){
    InputStreamReader isr = new InputStreamReader(stream);
    BufferedReader reader = new BufferedReader(isr);
    StringBuilder response = new StringBuilder();

    String line = null;
    try{
        while ((line = reader.readLine()) != null){
            response.append(line);
        }
    }
    catch (IOException e){
        Log.e("Error caught","Error in ConvertStreamToString",e);
    }
    catch(Exception e){
        Log.e("Error caught","Error in ConvertStreamToString",e);
    }
    finally {
        try{
            stream.close();
        }
        catch (IOException e){
            Log.e("Error caught","Error in ConvertStreamToString",e);
        }
        catch (Exception e){
            Log.e("Error caught","Error in ConvertStreamToString",e);
        }
    }
    return response.toString();
}
```

Şekil 6.5 ConverStreamToString Fonksiyonu

- **MakeNetworkCall:** Modelin çalıştığı server ile android studio'nun çalıştığı local server'ın iletişimi için kullanılır.

```
private class MakeNetworkCall extends AsyncTask <String, Void, String>{

    @Override
    protected void onPreExecute(){
        super.onPreExecute();
        System.out.println("Please Wait ...");

    }

    @Override
    protected String doInBackground(String... arg) {

        InputStream is = null;
        String URL = "http://10.0.2.2:5000/predict_home_price";
        Log.d("Error Caught","Url" + URL);
        String res = "";

        is = ByPostMethod(URL);
        if (is != null){
            res = ConvertStreamToString(is);
        }
        else{
            res = "Something went wrong";
        }
        return res;
    }

    @Override
    protected void onPostExecute(String s) {
        super.onPostExecute(s);

        DisplayMessage(s);
        Log.d("Error Caught","Url" + s);
    }
}
```

Şekil 6.6 MakeNetworkCall Fonksiyonu

6.4 Uygulamaya Ait Ekran Görüntüleri

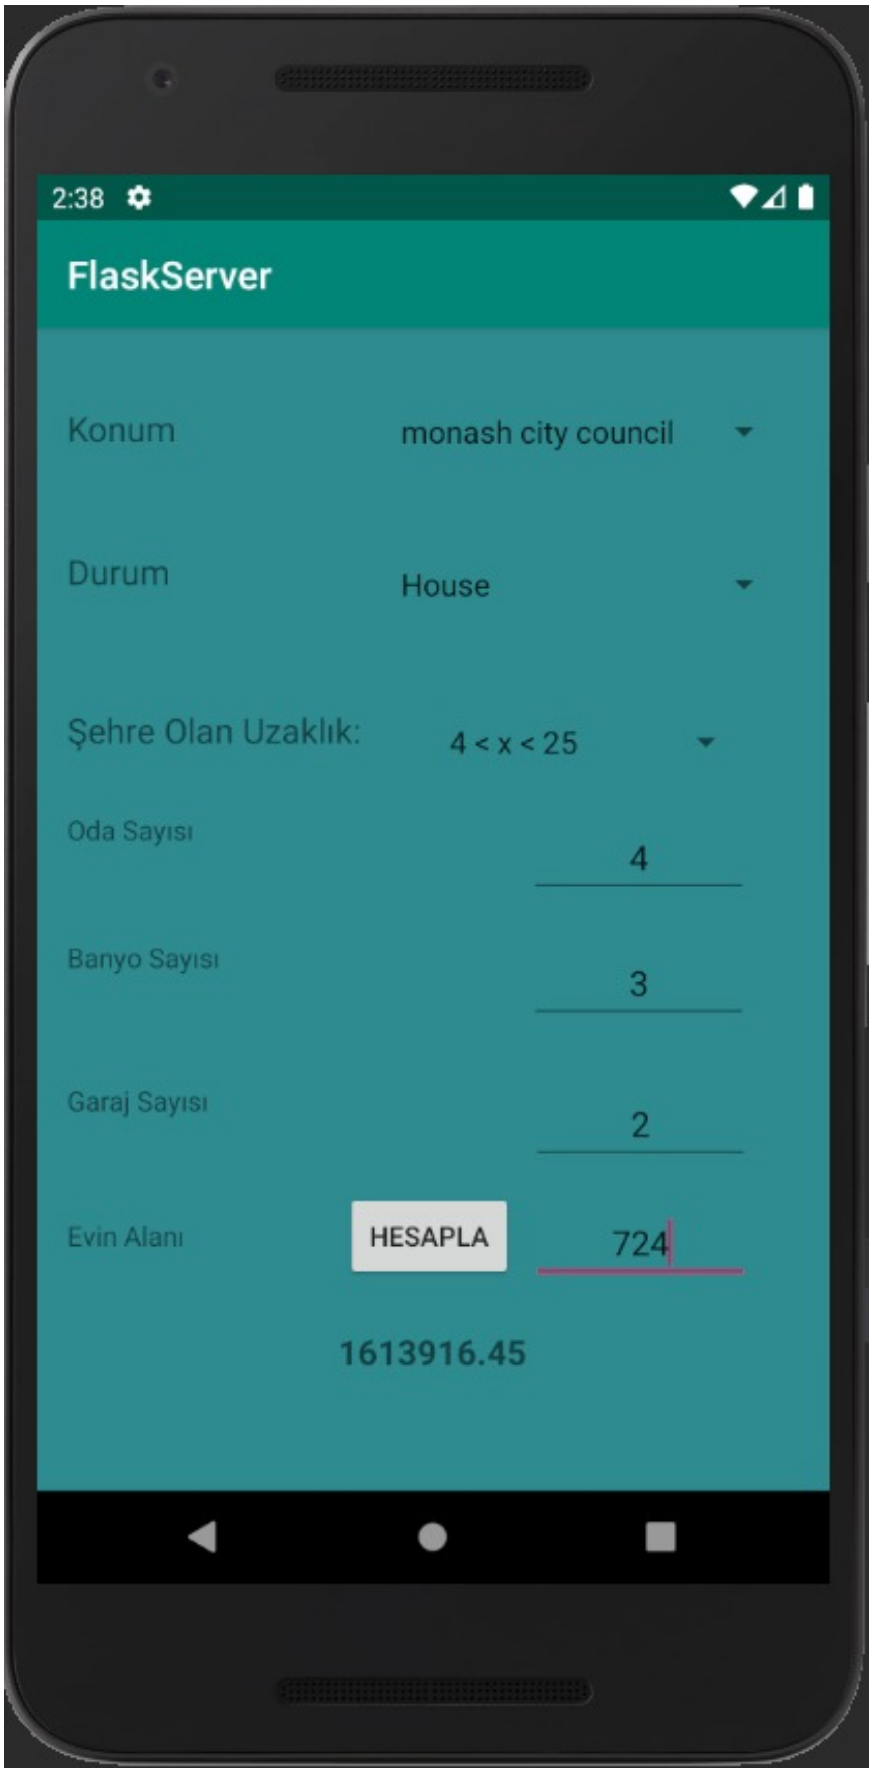

Şekil 6.7 Monash City İçin Örnek Ekran Çıktısı

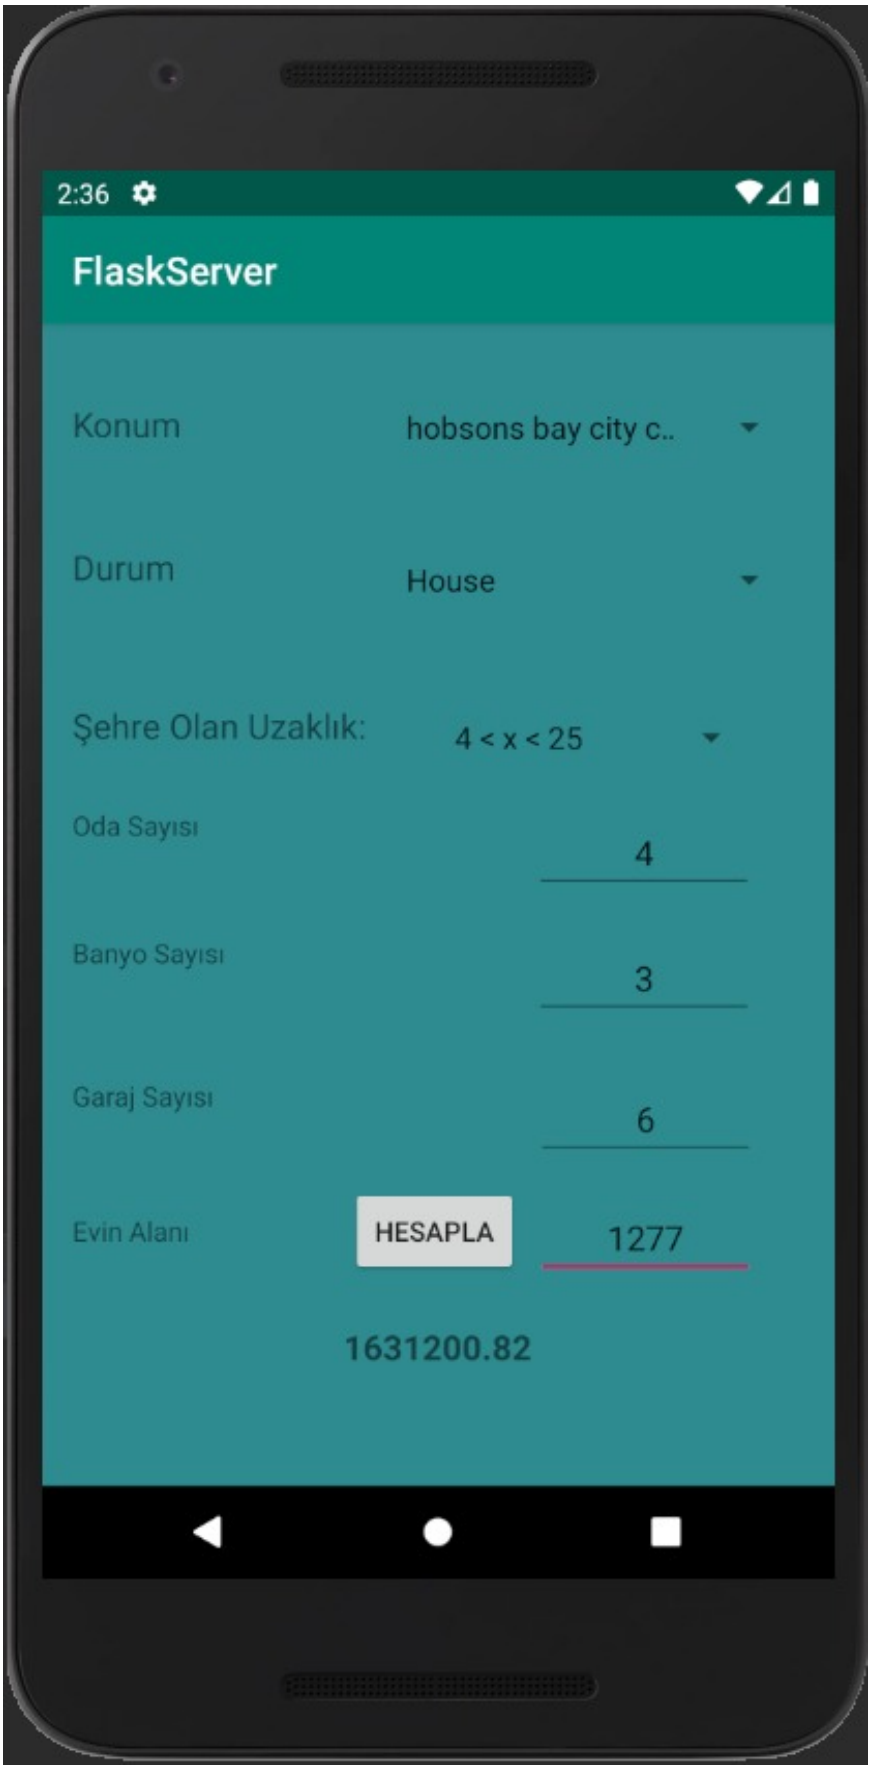

Şekil 6.8 Hobsons Bay City İçin Örnek Ekran Çıktısı

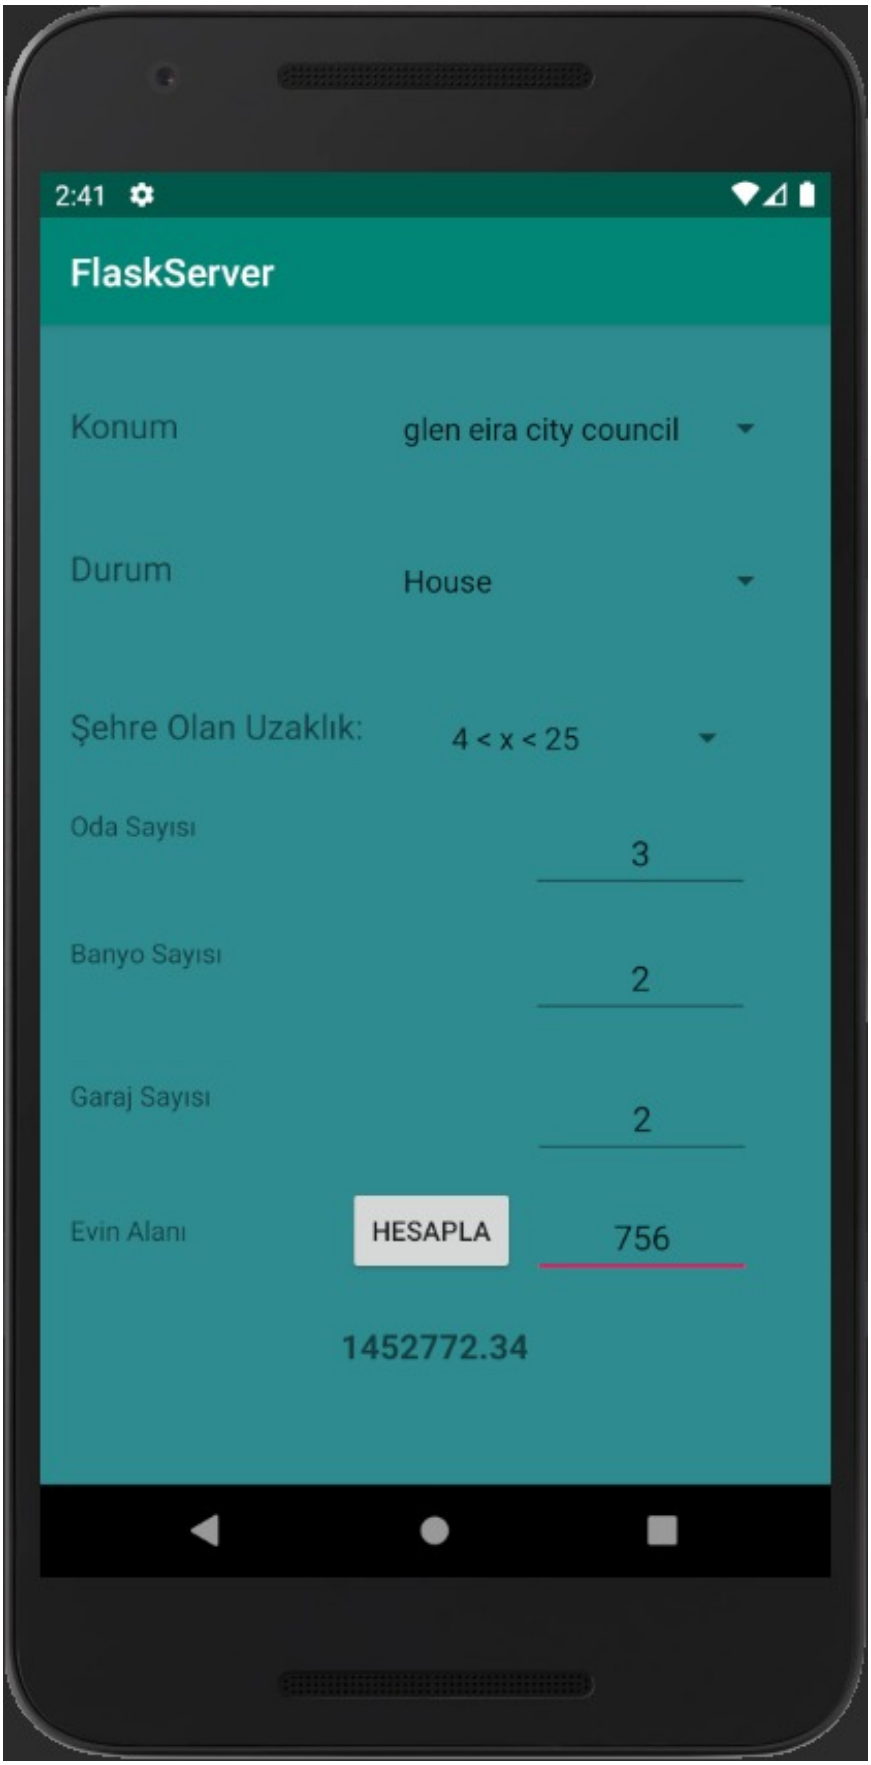

Şekil 6.9 Glen Eira City İçin Örnek Ekran Çıktısı

7
PERFORMANS ANALİZİ

Deneysel sonuçlar Python dili kullanılarak elde edilmiştir.Veri seti üzerinde çalışıldıktan sonra elde edilen sonuçlar Tablo 7.1 de verilmiştir. Lineer regresyon daha önceden de belirtilmiş olduğu gibi temel model olarak hareket etmiştir ve yüksek doğruluk payına sahip olmuştur. Ridge Regresyon ve Lasso Regresyon Tablo 7.1 de görüleceği üzere Lineer regresyon gibi daha düzgün değerler verebiliyorken, Regression Tree çok daha kötü sonuçlar vermiştir. Dahası, görülüyor ki Neural Network bu veri seti üzerinde efektif olarak çalışmamaktadır.

Model	**Model Score**
Linear Regression	0.6117386364935725
Lasso Regression	0.6006054524234776
Regression Tree	0.459135
Ridge Regressor	0.611738020
	LOSS
ANN	0.44444

Tablo 7.1 Modellerin Performanslarının Karşılaştırılması

Yorumlanabilirlik açısından Lineer regresyon kullanılarak geliştirilen mobil uygulama ile yapılan tahminler takip eden görsellerde belirtilmiştir.

Aşağıda girilen parametre değerlerine göre gerçek fiyatı bulunan bir evin tahmin edilen fiyatları yan yana verilmiştir.

CouncilArea	Rooms	Distance	Bathroom	Car	Total	Type	Price	Estimated Price
Yarra City Council	2	1	1	1	202	h	1480000	1181859.832
Yarra City Council	3	1	2	0	284	h	1465000	1480155.424
Moonee Valley City Council	3	2	2	1	528	t	840000	860110.8423
Moonee Valley City Council	3	2	2	5	786	h	1042000	1344401.015
Port Phillip City Council	2	1	1	0	202	h	1275000	1480551
Darebin City Council	4	2	2	1	802	h	1717500	1315216.995
Darebin City Council	3	2	3	2	686	h	2000000	1335210.311
Darebin City Council	3	2	1	2	592	h	1540000	1015512.604
Darebin City Council	4	2	2	2	718	h	1830000	1345221.705
Hobsons Bay City Council	5	2	3	3	997	h	1525000	1704322.126
Hobsons Bay City Council	2	2	1	2	417	t	720000	483640.2615
Hobsons Bay City Council	3	2	1	2	626	h	1120000	1012664.947
Hobsons Bay City Council	4	2	1	4	655	h	780000	1243833.351
Hobsons Bay City Council	4	2	3	6	1277	h	1780000	1631200.821

Şekil 7.1 Deneysel Sonuçlar 1

CouncilArea	Rooms	Distance	Bathroom	Car	Total	Type	Price	Estimated Price
Stonnington City Council	3	2	2	2	206	t	1205000	1602741.177
Stonnington City Council	3	2	1	1	333	h	1870000	1771611.8
Boroondara City Council	3	2	2	2	579	h	1662000	1929383.923
Boroondara City Council	3	2	2	3	847	h	1665000	1963262.827
Boroondara City Council	2	2	1	2	704	h	1445000	1602437.385
Monash City Council	4	2	3	2	724	h	1415000	1613916.447
Glen Eira City Council	2	2	1	2	599	h	1275000	1122722.048
Glen Eira City Council	4	2	1	4	786	h	1420000	1524620.194
Glen Eira City Council	3	2	2	2	756	h	1425000	1452772.343

Şekil 7.2 Deneysel Sonuçlar 2

8
SONUÇ

Özet olarak, bu raporda ev fiyatlandırması için çeşitli modeller üzerinde çalışılıp, içlerinden yorumlanabilirlik ve kolay uygulanabilirlik açısından en iyi olarak değerlendirilen Lineer Regresyon seçilerek bir mobil uygulamanın nasıl yapılacağı irdelenmiştir. Veri seti ilk olarak yorumlandı, daha sonra çeşitli temizleme işlemlerinden geçirilerek daha sade bir hale getirildi.Sonrasında JSON formatında çıktı alındı ve RESTApi altyapısı ile bir Android uygulaması geliştirildi.

Referanslar

[1] T. Pino. (2018). Melbourne housing data set, [Online]. Available: https://www.kaggle.com/anthonypino/melbourne-housing-market.

[2] P. D. S. Kul. (2018). Korelasyon analizi, [Online]. Available: http://www.p005.net/analiz/korelasyon-analizi.

[3] A. Massachi. (2019). Getting started with kaggle: House prices competition, [Online]. Available: https://www.dataquest.io/blog/kaggle-getting-started/.

[4] R. Langford. (2017). Kategorik alanların değiştirilmesi, [Online]. Available: https://towardsdatascience.com/the-dummys-guide-to-creating-dummy-variables-f21faddb1d40.

[5] (). Scikitlearn, [Online]. Available: https://scikit-learn.org/stable/about.html.

[6] C. Basics. (2020). Machine learning project, [Online]. Available: https://www.youtube.com/watch?v=rdfbcdP75KI&list=PLeo1K3hjS3ut2o1ay5Dqh-r1kq6ZU8W0M.

[7] J. Moody. (2019). What does rmse really mean? [Online]. Available: https://towardsdatascience.com/what-does-rmse-really-mean-806b65f2e48e.

[8] B. Roy. (2020). All about feature scaling, [Online]. Available: https://towardsdatascience.com/all-about-feature-scaling-bcc0ad75cb35.

[9] M. Gupta. (2019). Ml | feature scaling, [Online]. Available: https://www.geeksforgeeks.org/ml-feature-scaling-part-2/.

[10] H. Qi. (2017). How to initialize biases in a keras model? [Online]. Available: https://stackoverflow.com/questions/40708169/how-to-initialize-biases-in-a-keras-model.

[11] KerasIO. (2018). Layer weight initializers, [Online]. Available: https://keras.io/api/layers/initializers/.

[12] A. O. Site. (2020). Spinners, [Online]. Available: https://developer.android.com/guide/topics/ui/controls/spinner.

[13] ——, (2019). Jsonobject, [Online]. Available: https://developer.android.com/reference/org/json/JSONObject.

Özgeçmiş

BİRİNCİ ÜYE

İsim-Soyisim: Atakan TEKOĞLU
Doğum Tarihi ve Yeri: 01.08.1995, İstanbul
E-mail: atakantekoglu@gmail.com
Telefon: 0537 295 82 82
Staj Tecrübeleri: -

İKİNCİ ÜYE

İsim-Soyisim: Süleyman Ali Burak ÇINAR
Doğum Tarihi ve Yeri: 21.02.1998, Kocaeli
E-mail: sabc4129@gmail.com
Telefon: 0506 262 48 62
Staj Tecrübeleri: -

Proje Sistem Bilgileri

Sistem ve Yazılım: Windows İşletim Sistemi, Anaconda, Jupyter Notebook, Android Studio, PyCharm, Visual Studio Code
Gerekli RAM: 8GB
Gerekli Disk: 512MB